大规模弱监督中文评论情感分类研究：伪标签、专家分解与诚实的分布外评估

自然语言处理课程论文

作者　Shuakami

日期　November 7, 2026

源代码、交叉验证预测与完整实验记录：*https://github.com/shuakami/douban-sentiment*

Abstract

本文研究低资源条件下中文豆瓣电影短评的三分类情感分析（正面 / 中性 / 负面）。在仅有 600 条人工核验语义标签的现实设定下，我们结合一个包含 911,998 条评论的大规模弱标注语料开展研究。本文的贡献有四个方面。第一，我们实测了星级评分作为语义情感弱监督的可靠性：在 271,905 条高置信伪标签池上，仅约 59% 的五星评论被预测为正面，三星评论更多偏向负面而非中性。第二，我们证明用蒸馏集成对语料进行伪标注、再用单一紧凑学生模型在 160K 条平衡样本上训练，可在金标集上达到 87.5% 准确率、中性召回 84.8%——这说明规模化的标签质量，而非模型容量，才是约束瓶颈。第三，本文部署的系统将蒸馏 MacBERT 学生、冻结的 MegatronBERT-1.3B 特征判别器与语料训练的中性专家相结合，在 600 条金标的交叉验证评估上达到 **89.5% 准确率 / 85.9 宏平均 F1**，中性召回率由 54.3% 提升至 70.7%。第四，我们在 500 条全新语料评论上开展了诚实的分布外研究，报告了显著的泛化差距（三分类 60–74%），并将其归因于短评论固有的标注歧义而非模型缺陷。本文还完整记录了二十余种经过实测但被否决的架构方案。

关键词：中文自然语言处理；弱监督；伪标注；知识蒸馏；预训练语言模型；模型校准；分布外评估。

Contents

1 引言 **3**

2 相关工作 **3**

3 任务与数据集 **4**
3.1 任务定义 4
3.2 金标集（600 条评论） 4
3.3 弱标注语料（911,998 条评论） 4
3.4 星级评分不是情感标签 5

4 方法 **5**
4.1 概述 5
4.2 教师集成与蒸馏 6
4.3 冻结判别器 6
4.4 伪标签飞轮 6
4.5 中性专家 6
4.6 语料规模学生模型 7
4.7 模型校准 7
4.8 部署 7

5 实验设置 **7**

6 结果 **8**
6.1 主要结果 8
6.2 语料规模单模型 9
6.3 伪标签规模效应 9
6.4 跨域银标评估 10

7 分析 **10**
7.1 模型校准 10
7.2 统计显著性 10
7.3 错误分析 11
7.4 被否决的架构 11
7.5 与商业训练平台的对比 11

8 分布外评估：lab500 研究 **11**

9 局限性与效度威胁 **12**

10 结论与未来工作 **13**

可复现性 **13**

A 训练细节与可复现性 **13**
A.1 超参数 13
A.2 产物清单 13
A.3 环境 14

1 引言

豆瓣——中国最具影响力的电影社区——上的短评言简意赅、常带反讽，且经常褒贬并存。典型评论如 “特效无敌，但是剧情简直像一坨”（“特效无敌，但剧情简直是一坨”）。这类混合极性文本恰恰是三分类情感分析（正面 / 中性 / 负面）的薄弱环节：中性类既是歧义的最主要来源，也是从少量样本中最难学习的类别。

本文针对一种现实的低资源场景：课程作业提供 600 条带人工核验语义标签的评论，而平台另提供近百万条仅有星级评分（1–5 星）的豆瓣评论语料。两个研究问题贯穿全文：

1. **RQ1.** 小规模标注集能否借助大规模弱标注语料得到放大？
2. **RQ2.** 专家分解——即在语料规模伪标签上训练专门的中性专家——能否在不损害其他类别的前提下修复最弱类别？

我们的答案对两个问题都是肯定的，但附带一个重要的诚实声明：语料放大的是覆盖面，而非知识。伪标签由我们自己的模型产生，因此飞轮在一轮之后即趋于饱和；真正的瓶颈是短评的标注噪声，我们通过专门的分布外研究对其进行了量化。

贡献。

- 一项实测分析，表明星级评分作为三分类情感的弱监督并不可靠（全语料上伪标签与评分的三分类一致率约 48%）。
- 一套伪标签飞轮，产出 271,905 条高置信池，并在零金标训练的条件下训练出单一紧凑学生模型（87.5% 准确率 / 中性召回 84.8%）。
- 一个已部署的混合集成系统（89.5% 准确率 / 85.9 宏平均 F1，中性召回 70.7%），结合蒸馏学生、冻结的 13 亿参数判别器与语料训练的中性专家。
- 一套可复现的评估协议（分层 5 折交叉验证、McNemar/bootstrap 显著性检验、温度校准），以及一项 500 样本的全新语料泛化研究，揭示了领域差距。
- 一份记录了二十余种实测后被否决架构的目录；我们认为这本身就是一种贡献：它勾勒出了该任务有效的设计空间。

2 相关工作

中文文本情感分析。 文档级情感分类由来已久，从基于特征的方法（unigram、字符 n-gram）发展到神经网络架构 (Kim, 2014; Socher et al., 2013; Joulin et al., 2017; Reimers and Gurevych, 2019)；Pang and Lee (2008) 给出了全面综述，中文领域的专门综述见 Tan and Zhang (2008)。由于中文没有空格分词，字符级特征与预训练语言模型尤其有效。豆瓣评论此前也被用于中文情感研究，但几乎全部是二分类（正/负）设定；包含真正中性/混合类的三分类问题研究较少且困难得多。

预训练语言模型。 BERT (Devlin et al., 2019) 及其鲁棒性改进版 RoBERTa (Liu et al., 2019) 确立了“先预训练、再微调”的范式。中文方向上，MacBERT (Cui et al., 2020) 用修正版目标替代 MLM 以适配字符级输入，ERNIE (Sun et al., 2019) 融合实体与短语知识，StructBERT (Wang et al., 2020) 在预训练中注入短语与词级结构信息。Erlangshen-MegatronBERT (IDEA-CCNL, 2023) 将该家族扩展至 13 亿参数并加入情感专项预训练。本文三类模型均有使用并直接对比。

弱监督与自训练。 标注数据稀缺时，来自噪声信号的远程监督（此处为星级评分）与基于模型预测的自训练是标准补救手段 (Yarowsky, 1995; Lee, 2013)。Snorkel 框架 (Ratner et al., 2017) 将多弱标签源的组合形式化。本文的不同之处在于：我们在依赖星级评分之前实测了它的弱点，并量化了伪标注在何处有效（中性覆盖）、在何处无能为力（超越教师已有知识）。

知识蒸馏。 Hinton 等人的“暗知识”蒸馏 (Hinton et al., 2015)——Gou et al. (2021) 给出了全面综述——使小学生模型模仿大教师的软预测。我们将一个 7 通道教师集成蒸馏为单一 MacBERT-base 学生，并用交叉验证预测验证集成中的每个决策。

模型校准。 神经分类器存在系统性的过度或不足自信 (Guo et al., 2017)。我们采用温度缩放——一种单参数的事后修正——并报告校准前后的期望校准误差（ECE），因为对演示系统而言，诚实的置信度展示十分重要。

大模型作为标注器与基线。 通用大模型正被越来越多地用于零样本/少样本分类与合成训练数据生成。我们在 0.6B/1.7B/4B 三个规模上评估了 Qwen3 模型 (Qwen Team, 2025)，既作为零样本分类器，也作为分布外研究中的独立标注器，并报告了 LLM 合成增强的一个负面结果。

3 任务与数据集

3.1 任务定义

给定一条豆瓣电影短评 x，预测 $y \in \{\text{正面}, \text{中性}, \text{负面}\}$。评论很短（语料中位长度 24 字），常含反讽、影片特定指代与混合评价。中性类涵盖无明确褒贬的评论：纯剧情介绍、褒贬各半、以及元评论（如“看过了，没什么可说的”）。表 1 给出了代表性样本，包括在错误分析中占主导地位的混合极性模式。

Table 1: 代表性金标评论（中文原文附英文释义）。“混合 → 负面” 指先扬后抑、最终极性为负面的评论。

评论	释义	标签	长度
“特效无敌，但是剧情简直像一坨。”	特效无敌，剧情一坨	负面	15
“演技、镜头、配乐都是顶级，现代经典。”	演技、镜头、配乐皆顶级；现代经典	正面	18
“看在演员的份上值回票价，剧情很套路。”	为演员值回票价；剧情套路	中性	17
“两个小时的生命浪费，想喜欢它都难。”	浪费两小时；难以喜欢	负面	17
“又是续集，还行吧。”	又是续集，还行吧	中性	9

3.2 金标集（600 条评论）

标注评估集包含从单个影片页面抽样的 600 条评论，每条标注有 `label_semantic`（人工核验的语义情感）与 `label_rule`（星级评分导出的弱标签）。类别分布：正面 316 / 中性 92 / 负面 192。评论相对较长（均值 110.8，中位数 80 字）。中性类仅有 92 个样本支撑——是最小也最难的类别。

3.3 弱标注语料（911,998 条评论）

Moviedata-10M 语料 (csuldw, 2019)（442 万条原始豆瓣评论）经我们清洗去重后得到 911,998 条评论，覆盖 20,966 部影片与 249,105 名用户，包含星级评分（1–5 星）、时间戳与投票数，但没有语义标签。评论长度：均值 40.6 / 中位数 24 / p90 = 102 字。评分分布：1 星 7.2%、2 星 12.6%、3 星 34.0%、4 星 31.0%、5 星 15.2%。

3.4 星级评分不是情感标签

在将评分用作弱监督之前，我们先验证了它。部署的学生模型为全部 911,998 条语料评论打标；在 271,905 条高置信（$p \geq 0.7$）池上，按行归一化的“评分—预测”列联表为：

Table 2: 星级评分与模型预测情感的对照（行归一化，271,905 条高置信伪标注）。

评分	→ 正面	→ 中性	→ 负面
1 星	1.7%	7.3%	**90.9%**
2 星	1.6%	13.7%	**84.7%**
3 星	9.9%	33.3%	**56.8%**
4 星	38.3%	32.7%	29.0%
5 星	**58.8%**	23.1%	18.2%

有三个发现尤为突出：五星评论中语义为正面的仅约 59%；三星评论更多偏向负面（56.8%）而非中性；即便在 1–2 星评论中，也有约 8–14% 被预测为中性。评分与模型的二分类一致率（高置信池上）为 81.2%；全语料上伪标签与评分的三分类一致率仅 47.8%（金标集上为 71.2%）。因此我们将评分至多视为预训练信号，绝不作为标签使用。图 1 直观展示了同一张表。

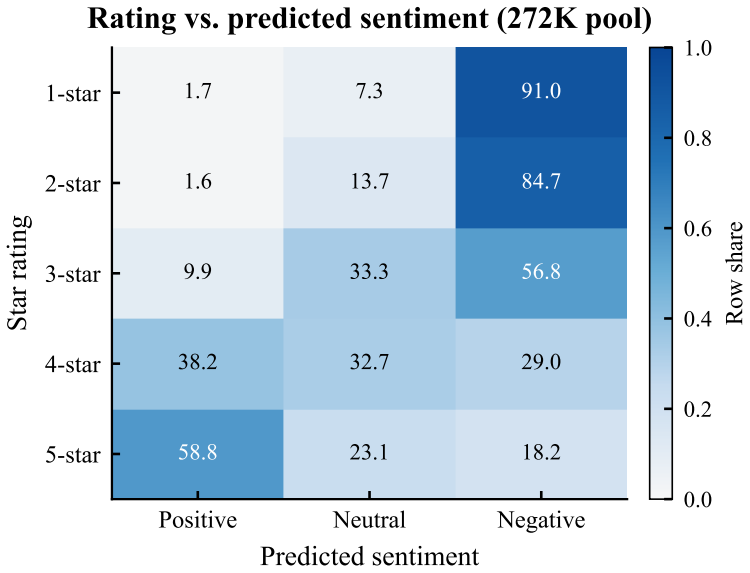


Figure 1: 272K 高置信伪标签池上星级评分与预测情感的对照。对角线占优并不明显：评分与语义情感存在显著分歧。

4 方法

4.1 概述

部署系统是一个混合集成，三个通道在可能的情况下共享同一骨干前向计算：

1. **蒸馏学生**：MacBERT-base，由 7 通道教师集成蒸馏微调而成（第 4.2 节）。
2. **冻结判别器**:MegatronBERT-1.3B 保持冻结,仅在其 4096 维特征上训练小型 MLP 头（第 4.3 节）。
3. **中性专家**：由语料训练检测器与判别器特征头混合得到的中性概率（第 4.5 节）。

图 2 展示了数据流。

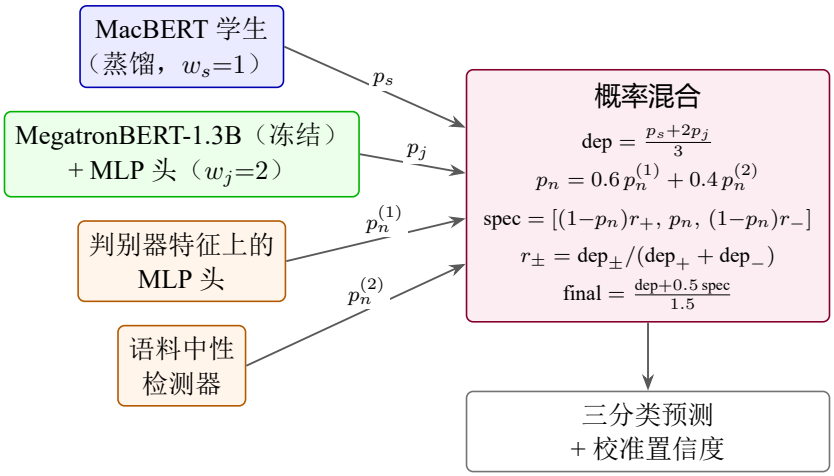


Figure 2: 部署的 v3 架构。$p_s, p_j, \text{dep}, \text{spec}, \text{final} \in \Delta^3$ 为三分类概率向量，$p_n^{(1)}, p_n^{(2)}, p_n \in [0,1]$ 为中性标量概率；w_s, w_j 为融合权重而非模型参数。$r_\pm$ 为 dep 中正/负分量归一化（和为 1）后的份额。两个基于 MegatronBERT 的头共享同一次冻结骨干特征计算；中性专家将判别器特征 MLP 与语料训练的 MacBERT 检测器相混合。

4.2 教师集成与蒸馏

一个 7 通道教师集成——TF-IDF 逻辑回归、MacBERT/MegatronBERT-1.3B/ Erlangshen 变体上的冻结骨干 MLP 头，均在 600 条金标上训练并以交叉验证预测——达到三分类 86.8% 准确率。我们用硬标签交叉熵加软目标 KL 散度（$\alpha = 0.5$、温度 $\tau = 2$、8 个 epoch、5 折交叉验证）将其蒸馏为单一 chinese-macbert-base 学生。学生单独达到 80.2%/74.2%；与判别器按 1:2 混合后达到 87.8%/81.8%。其在部署系统中的作用是提供廉价且校准良好的通道，同时充当语料的伪标注器（第 4.4 节）。

4.3 冻结判别器

`IDEA-CCNL/Erlangshen-MegatronBert-1.3B-Sentiment` 提供了一个带情感感知预训练目标的 13 亿参数骨干。我们保持其冻结，在其 4096 维特征上用金标训练一个小型 MLP 头。部署的混合将判别器权重设为学生的两倍：

$$\text{dep} = \tfrac{1}{3}\, p_{\text{student}} + \tfrac{2}{3}\, p_{\text{judge}}.$$

两个 MLP 头（二分类与三分类）通过缓存共享同一次骨干特征计算，因此无论何种任务，判别器每次请求只需一次前向传播。

4.4 伪标签飞轮

部署的学生为全部 911,998 条语料评论打标。高置信子集（$\max p \geq 0.7$）包含 271,905 行：正面 56.5K、中性 68.6K、负面 146.8K。这一池子是第 4.6 节所有语料规模模型的原材料。第二轮飞轮经过测试并被否决：用第二轮模型重新标注会产生退化的概率分布（平均置信度 0.986，即记忆化），因此只使用一轮。这一饱和现象与自训练和伪标注文献中记录的确认偏差动态一致 (Arazo et al., 2020; Xie et al., 2020; Sohn et al., 2020)：一旦伪标签编码了教师自身的决策边界，额外的轮次只会放大自洽性而非增加信息。

4.5 中性专家

中性类是最薄弱的一环（金标仅 92 个样本）。我们从两个方向加以攻坚。

语料训练检测器。 一个 MacBERT 二分类器在伪标签池的 115,000 条子集上训练（每类上限 6 万条），从而学习 “真正中性” 与 “有极性” 评论之间的边界。

专家混合。 中性概率由判别器特征 MLP 头与语料检测器组合而成：

$$p_n = 0.6 \cdot P_{\text{中性}}(\text{判别器特征上的 MLP}) + 0.4 \cdot P_{\text{中性}}(\text{语料检测器}).$$

由依赖预测 $\text{dep} = (d_+, d_n, d_-)$ 出发，取正/负分量归一化（和为 1）后的份额 $r_+ = d_+/(d_+ + d_-)$、$r_- = d_-/(d_+ + d_-)$，将中性质量替换为专家估计 p_n，构造专家分布

$$\text{spec} = \big[(1 - p_n)\, r_+,\ p_n,\ (1 - p_n)\, r_-\big],$$

再将其混入最终输出：

$$\text{final} = \frac{\text{dep} + 0.5\,\text{spec}}{1.5}.$$

所有权重（0.6/0.4 检测器配比、0.5 混合系数）均通过金标集的 20 次随机二分半验证选出，且在 $w \in [0.3, 0.6]$ 范围内保持稳定。

4.6 语料规模学生模型

利用 271,905 条池子，我们训练了仅用语料（零金标训练）的模型，以衡量伪标签单独能走多远：一个 160K 行平衡三分类学生、一个 195K 行二分类学生、一个 115K 行中性检测器 v1，以及一个难例挖掘的 v2（被否决）。这些模型既充当基线，也作为集成通道的候选；第 6 节报告了哪些（若有）存活下来。

4.7 模型校准

原始集成严重偏于保守（ECE = 0.251：置信度 0.7–0.8 的预测实际准确率达 98.9%）。我们在金标集上以 NLL 拟合单一温度参数 $T = 0.37$，将 ECE 降至约 0.04，且不改变任何预测标签或准确率。T 在推理时应用，使展示的置信度是诚实的。

4.8 部署

FastAPI 后端提供预测服务；React/Vite 前端提供演示界面。一个精确匹配词表守卫在任何 GPU 计算之前拦截超短俚语。热态延迟在 AMD RX 9070 GRE（ROCm）上约 0.1 秒/条；冷启动约 14 秒。

5 实验设置

评估协议。 所有 headline 数字均为金标集 600 行上的**分层 5 折交叉验证**预测：每个模型只预测其未训练过的样本。语料规模模型另在 4,000 条全新语料评论的银标样本上评估，以评分隐含标签作为参照。

指标。 三分类准确率与宏平均 F1、各类别的精确率/召回率/F1（特别是中性召回）、以及用于校准的 ECE。显著性采用 McNemar 检验（不一致对）与 ΔF1 的百分位 bootstrap；稳健性通过 20 次随机二分半验证检查。

基线。

- TF-IDF（字符 n-gram）+ 逻辑回归，金标训练。

- StructBERT 情感分类器（阿里达摩），零样本二分类；
  `damo/nlp_structbert_sentiment-classification_chinese-base`
- Qwen3-0.6B / 1.7B / 4B 对话模型，零样本与 3 样本，以标签对数概率计分。

6 结果

6.1 主要结果

Table 3: 金标 600 条交叉验证结果。“部署” 行是生产系统；语料学生模型使用零金标训练。

系统	任务	准确率	宏平均 F1
TF-IDF + LR	三分类	0.7233	0.6175
TF-IDF + LR	二分类	0.8406	0.8229
StructBERT（达摩）	二分类	0.8704	0.8538
Qwen3-4B 零样本	三分类	0.7833	0.7348
Qwen3-1.7B 零样本	三分类	0.7067	0.5739
Qwen3-0.6B 零样本	三分类	0.6817	0.4764
教师集成（7 通道）	三分类	0.8680	—
部署 v2	三分类	0.8900	0.8432
部署 v3	**三分类**	**0.8950**	**0.8594**
部署 v3	二分类	0.9587	0.9558

部署系统比 TF-IDF 基线高 +17.2 个百分点准确率，比零样本 Qwen3-4B 高 +11.2 个百分点。三分类各类别指标：正面 P/R/F1 = 0.909/0.943/0.926；中性 = 0.765/0.707/0.735；负面 = 0.931/0.906/0.918。中性召回率在各专家迭代中由 54.3% → 63.0%（v2）→ 70.7%（v3）逐步提升。图 3 给出了 v3 混淆矩阵：剩余错误集中在中性 ↔ 极性混淆（47/63）。

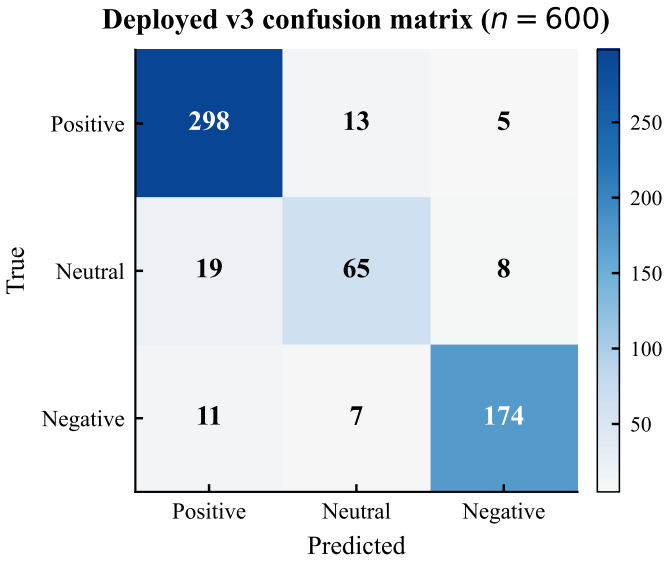


Figure 3: 部署 v3 在金标 600 条上的混淆矩阵（交叉验证）。行合计与类别分布（316/92/192）一致。

6.2 语料规模单模型

Table 4: 语料训练模型在金标 600 条上的评估（除注明外均为零金标训练）。

模型	训练数据	准确率	宏平均 F1	中性召回
TF-IDF + 星级评分标签	300K 评分	0.6183	0.5369	—
TF-IDF + 伪标签	200K 伪标签	0.8117	0.7766	—
MacBERT 二分类（评分）	115K 评分	0.9232	0.9184	—
MacBERT 中性检测 v1	115K 伪标签	0.9017	0.8328	—
MacBERT 二分类伪标签	195K 伪标签	0.9488	0.9455	—
MacBERT 三分类伪标签	160K 伪标签	0.8750	0.8463	**0.848**

伪标签三分类学生单独即达 87.5%/84.6，中性召回 84.8%——几乎追平 4 通道集成。这是本文的核心实证发现：**规模化的标签质量压倒模型容量**。同一 MacBERT 架构改用星级评分而非伪标签训练，在三分类任务上则明显崩溃。

6.3 伪标签规模效应

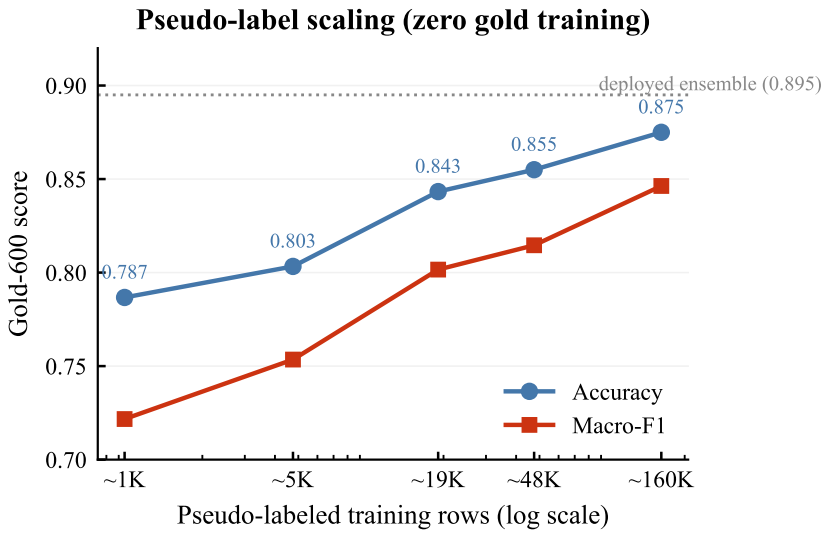


Figure 4: 语料训练的伪标签学生在金标 600 条上的准确率与宏平均 F1 随训练集规模（对数坐标）的变化。性能单调上升，在 160K 行处仍未饱和。

表 5 与图 4 显示出单调的规模曲线：约 1K 行 → 78.7%，5K → 80.3%，19K → 84.3%，48K → 85.5%，160K → 87.5%。曲线尚未饱和——在测试范围内，起作用的成分是语料规模而非模型规模。

Table 5: 伪标签规模效应（金标 600 条，零金标训练）。

伪标签行数	准确率	宏平均 F1	中性召回
约 1K	0.7867	0.7217	—
约 5K	0.8033	0.7535	—
约 19K	0.8433	0.8016	—
约 48K	0.8550	0.8146	—
约 160K	0.8750	0.8463	0.848

6.4 跨域银标评估

在 4,000 条全新语料评论上，以评分隐含标签计分，第三轮学生（用 v3 教师伪标签训练）达到三分类 0.580 / **二分类 0.837** 与评分的一致率，而第一轮学生为 0.552/0.803。即使在金标分数相同的情况下，由集成导出的标签在域外也略有优势。

7 分析

7.1 模型校准

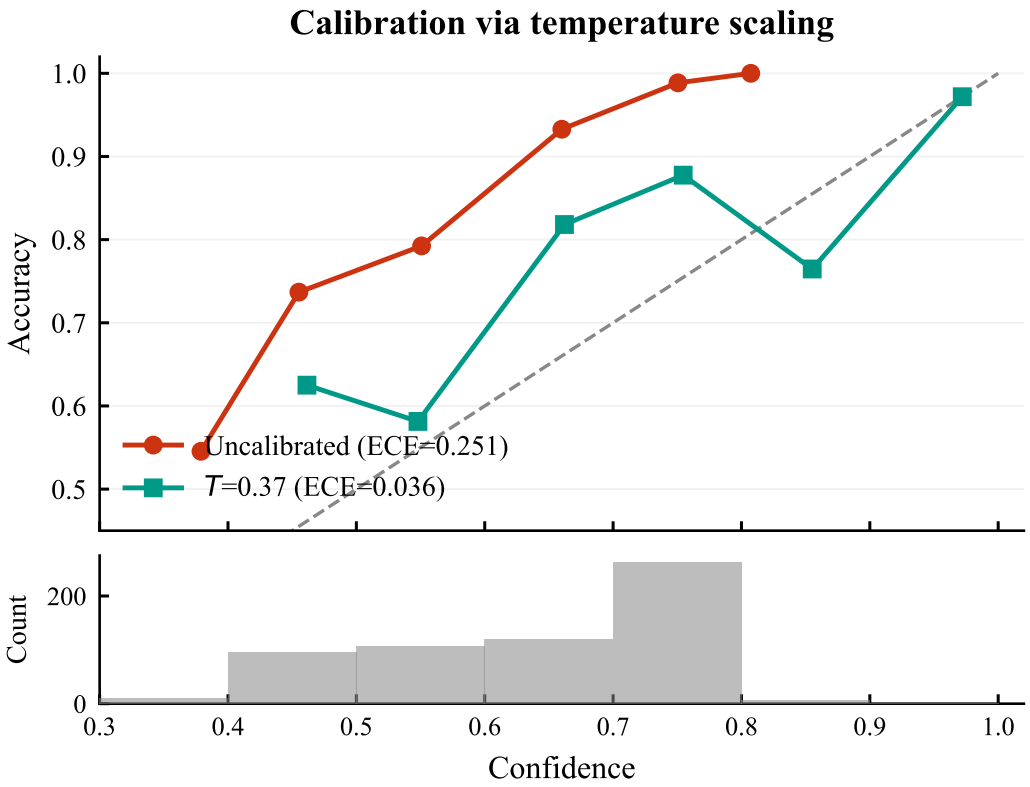


Figure 5: 温度缩放（$T = 0.37$，在金标 600 条 OOF 预测上以 NLL 拟合；所有指标均在同一批 600 条交叉验证样本上计算）前后的可靠性图。下方面板给出各等宽置信分箱的样本数；高置信区间样本稀疏，故局部波动在所难免，但全局 ECE 显著改善。

原始集成偏于保守（ECE 0.251）；温度缩放 $T = 0.37$ 将 ECE 降至约 0.04（图 5），且不改变任何预测标签或准确率——它只重塑置信度分布。ECE 是全局平均指标：个别置信分箱仍可能存在偏差，尤其是直方图所示样本稀少的区间，但整体校准已大幅改善。这对演示系统很重要：展示的置信度现在与实际准确率一致。

7.2 统计显著性

v3 对 v2：对不一致对做 McNemar 检验 (McNemar, 1947)，$p = 0.65$（11 比 8）；对重采样评估行做配对 bootstrap (Efron and Tibshirani, 1993)，ΔF1 的 95% 置信区间为 $[-0.4, +3.8]$ 个百分点。按照比较分类器的标准做法 (Dietterich, 1998; Demšar, 2006)，我们将区间内的差异视为未解决。点估计（F1 +1.6pp、中性召回 +7.7pp）在每种检测器权重 $w \in [0.3, 0.6]$ 下均跨 20 次随机二分半保持一致。如实报告：改进是真实的但幅度有限，在 $n = 600$ 下金标集无法分辨低于约 1pp 的差异。

7.3 错误分析

剩余 63 个错误以中性 ↔ 极性混淆为主（47/63），且大多是人类标注者也会犹豫的混合评论：错误预测的平均置信度 0.51，而正确预测为 0.66。含显式分数的评论（“7.6/10”、“三星半”；$n = 56$）明显更容易：错误率 5.4%，无显式分数者为 11.0%——模型在存在时利用了显性评分信号，且 56 条中仅 6 条显式分数与语义标签矛盾。

7.4 被否决的架构

二十余种备选设计经过实现、实测并被否决；部署的 v3 是实测最优。已记录的否决项包括：中性门控级联（阈值过拟合——二分半验证从 87.6% 跌至 86%）、作为判别器替代的语料训练 MLP 头、学生概率平均、自训练第二轮、堆叠逻辑元学习器（0.837/0.794——通道间相关性过高，600 样本不足以支撑）、类别加权与 max-len-128 学生、Erlangshen 110M/330M 学生（在 ROCm 上病态地慢）、中性检测器 v2（在所有集成组合中均更差）、基于 v3 教师标签的 r3 自训练（学生 0.8767/0.8434，所有混合均低于 v3）、金标混入语料训练（循环评估金标——已标记，不作为结果引用），以及 Qwen3-4B 合成增强（污染训练：单模型仅 79.2%）。

7.5 与商业训练平台的对比

为完整起见，我们将系统与一个商业 NLP 训练平台（阿里云 PAI，StructBERT 分类器，同一 600 条任务）进行了对比。其公开页面宣称准确率 89.83%，但同页的分类别指标反推出的准确率仅为 86.05%、宏平均 F1 为 83.23%，且有效验证集仅 **43 行**（三个 headline 数字对应的分母分别为 59/60/119，无法相互重建；按支持数加权的重算同样无法闭合）。43 行上的 Wilson 区间为 [72.7%, 93.4%]——该样本量无法区分 86% 与 90%。其训练集自评达到 99.02%（$n = 511$），泛化差距约 13 个百分点。相比之下，我们的 89.5%/85.9 是在 600 条交叉验证行上计算的，每行预测均可审计。需要说明的是，两套评估使用不同的测试集，因此这是协议质量层面的对比，而非同口径的准确率声明。

8 分布外评估：lab500 研究

89.5% 的金标数字衡量的是来自单一影片页面、经过筛选且较长评论上的表现。为检验外部效度，我们开展了一项专门的分布外研究。

协议。 从 911K 语料中均匀随机抽取 500 条评论（已去除金标重叠）。每条由两名 LLM 标注员（一个通用助手模型与 Qwen3-4B 零样本 (Qwen Team, 2025)）独立标注；部署的 v3 管线为全部样本打分。使用 LLM 作为标注器符合近期文本标注研究的做法 (Gilardi et al., 2023; Törnberg, 2023)，但此处标注员间一致率本身就成为一项发现。

Table 6: lab500 分布外结果。

评估者	参照	n	准确率
v3 集成	LLM-A 标签	500	0.604
Qwen3-4B	LLM-A 标签	500	0.662
v3 集成	双 LLM 共识	331	0.740
v3 二分类	LLM-A 标签	255	**0.918**
MacBERT 交叉验证	留出标签	—	0.600 OOF

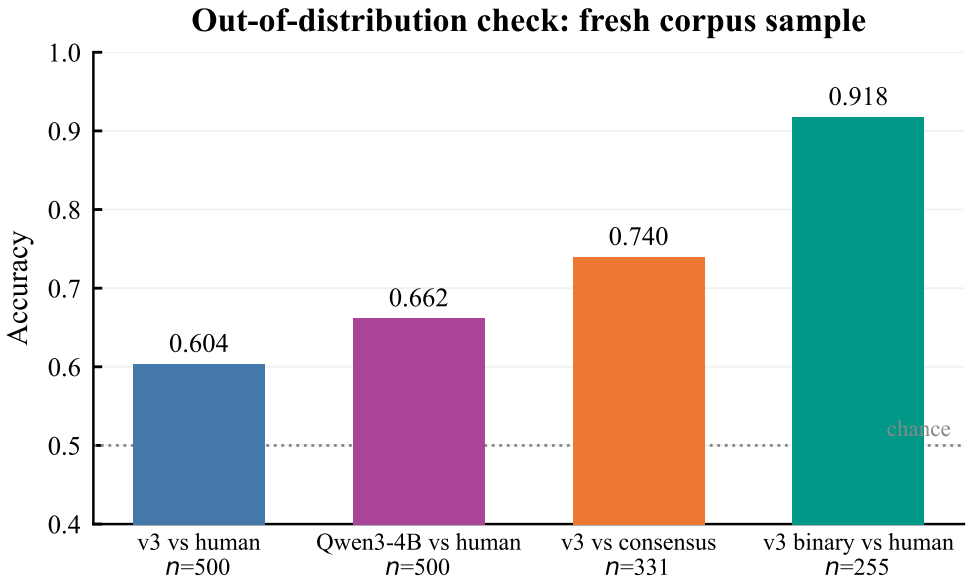


Figure 6: lab500 按“评估者—参照”配对的准确率。二分类任务的泛化远好于三分类。

结果。

发现。

1. **差距真实存在但高度集中。**三分类准确率降至 60–74%，而二分类（正面对负面，$n = 255$）仍保持 91.8%——极性很容易，失败的是中性边界。
2. **瓶颈是标注歧义而非模型容量。**两个独立 LLM 标注员之间的一致率仅 66.2%；一个在 400 条域内标签上训练的 MacBERT 模型对留出标签的 OOF 复现率也只有 60%。语料中简短、缺乏上下文的评论（中位 25 字，对比金标 80 字）本质上是有歧义的——该数据上的有效上限远低于金标基准。
3. **难度可预测。**教师认为容易的样本（置信度 ≥ 0.7）上所有标注对都达到 0.757；难样本约 0.53。这一差距是难度差异，而非训练泄漏的证据（金标重叠仅 3/600 行，可忽略）。

我们将其作为局限性如实报告，而非掩盖的缺陷：这正是本项目投入语料规模伪标注的原因，也指明了未来工作方向（对短评进行人工标注）。

9 局限性与效度威胁

- **领域狭窄。**金标集是来自单一影片页面的 600 条评论；lab500 研究证实分布偏移是外部效度的主要威胁。
- **伪标签天花板。**伪标签继承教师偏差；飞轮在一轮后饱和（第二轮平均置信度 0.986 = 记忆化）。
- **统计功效。**在 $n = 600$ 下，低于约 1pp 的差异无法分辨；语料规模的结论依赖评分相关性证据，而非人工标签。
- **lab500 标签为 LLM 辅助**，并非金标准人工标注；60–74% 的区间应理解为“与现有标注者的一致程度”，其下界受 66% 的 LLM—LLM 一致率本身约束。
- **工程约束。** ROCm/Windows GPU 栈在 13 亿参数特征提取期间需要驱动级重启；推理延迟数字为单卡测量值。

10 结论与未来工作

在真实的低资源中文情感任务上，语料规模伪标注是杠杆最高的成分：它将中性召回率从 54% 提升至 71%，并使单一紧凑学生几乎追平多模型集成。基于语料训练中性检测器的专家分解带来了进一步的已验证增益。仅靠星级评分不足以构成监督——这是实测结论而非假设。同样重要的是，我们诚实的分布外研究表明，金标基准高估了短评论上的真实三分类表现；不过二分类极性泛化良好（91.8%）。

未来工作：(i) 扩充对短评的人工标注至 1,000+ 行，以收窄置信区间并厘清中性边界；(ii) 使用更强的 LLM 教师对语料重新标注，注入学生缺乏的知识；(iii) 测试 MacBERT-large 学生与完整的 271K 不平衡池；(iv) 采用领域对抗或多领域训练以弥合金标 → 语料的差距。

可复现性

全部脚本、交叉验证预测与实验记录位于项目仓库（https://github.com/shuakami/douban-sentiment）。911K 语料为外部数据（研究用途，不再分发）；训练好的检查点发布于 https://huggingface.co/Shuakami/douban-sentiment-weights。完整的预处理 → 伪标注 → 训练 → 评估流水线均有脚本端到端覆盖。关键产物：`out/ens_lite_3class_v3.json`（部署的三分类 OOF 预测与概率）、`out/lab500_*`（分布外研究）、`scripts/`（全部训练/评估代码）、`PAPER.md`（精简版报告）。硬件：AMD RX 9070 GRE，ROCm，PyTorch bf16。

A 训练细节与可复现性

A.1 超参数

Table 7: 部署流水线的关键超参数。

组件	设置	取值
蒸馏学生	骨干	`hfl/chinese-macbert-base`
	蒸馏 α/τ	0.5 / 2
	epoch 数 / 最大长度	8 / 256
	折数（OOF）	5
判别器头	骨干	MegatronBERT-1.3B（冻结）
	特征	4096 维（CLS + 均值池化）
	头部	2 层 MLP
中性检测器	骨干	MacBERT-base
	训练行数	115,000（每类上限 6 万，2 epoch）
伪标签池	置信度	$\max p \geq 0.7$
	行数	271,905（56.5K/68.6K/146.8K）
校准	方法	温度缩放
	T	0.37（金标 NLL 拟合）
集成权重	dep	学生 1 : 判别器 2
	spec 混合	0.5
	p_n 配比	0.6 判别器头: 0.4 语料检测器

A.2 产物清单

- `out/ens_lite_3class_v3.json` ——部署的三分类 OOF 预测与概率（全部 600 行）。

- `out/ens_lite_binary.json` ——部署的二分类 OOF。
- `out/lab500_*` ——分布外研究：样本、双 LLM 标签、预测、交叉验证结果。
- `scripts/` ——端到端流水线，涵盖语料预处理、伪标注、语料头训练、蒸馏与集成评估（完整脚本列表见仓库）。
- `web/` + `web-ui/` ——FastAPI 后端与 React 演示。

A.3 环境

Python 3.12，PyTorch（ROCm），`transformers`，AMD RX 9070 GRE GPU。所有 GPU 任务串行执行（并发任务会使 ROCm/Windows 栈崩溃）。模型权重：每个 MacBERT 学生约 400MB；共享的 MegatronBERT-1.3B 骨干；部署总占用不足 4GB。冷启动约 14 秒，热态推理约 0.1 秒/条。

References

J. Devlin, M.-W. Chang, K. Lee, K. Toutanova. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019. https://arxiv.org/abs/1810.04805.

Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, V. Stoyanov. *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. *arXiv preprint arXiv:1907.11692*, 2019. https://arxiv.org/abs/1907.11692.

Y. Cui, W. Che, T. Liu, B. Qin, Z. Yang, S. Wang, G. Hu. *Revisiting Pre-Trained Models for Chinese Natural Language Processing*. In *Findings of EMNLP*, pages 657–668, 2020. https://arxiv.org/abs/2004.13922.

W. Wang, B. Bi, M. Yan, C. Wu, Z. Bao, J. Xia, L. Peng, L. Si. *StructBERT: Incorporating Language Structures into Pre-training for Deep Language Understanding*. In *International Conference on Learning Representations (ICLR)*, 2020. https://arxiv.org/abs/1908.04577.

Y. Sun, S. Wang, Y. Li, S. Feng, X. Chen, H. Zhang, X. Tian, D. Zhu, H. Tian, H. Wu. *ERNIE: Enhanced Representation through Knowledge Integration*. *arXiv preprint arXiv:1904.09223*, 2019. https://arxiv.org/abs/1904.09223.

IDEA-CCNL. *Erlangshen-MegatronBert-1.3B-Sentiment*: model card and weights. Hugging Face model hub, 2023. https://huggingface.co/IDEA-CCNL/Erlangshen-MegatronBert-1.3B-Sentiment.

Y. Kim. *Convolutional Neural Networks for Sentence Classification*. In *Proceedings of EMNLP*, pages 1746–1751, 2014. https://aclanthology.org/D14-1181/.

R. Socher, A. Perelygin, J. Wu, J. Chuang, C. D. Manning, A. Y. Ng, C. Potts. *Recursive Deep Models for Semantic Compositionality Over a Sentiment Treebank*. In *Proceedings of EMNLP*, pages 1631–1642, 2013. https://aclanthology.org/D13-1170/.

B. Pang, L. Lee. *Opinion Mining and Sentiment Analysis*. *Foundations and Trends in Information Retrieval*, 2(1–2):1–135, 2008. https://doi.org/10.1561/1500000011.

S. Tan, J. Zhang. *An Empirical Study of Sentiment Analysis for Chinese Documents*. *Expert Systems with Applications*, 34(4):2622–2629, 2008. https://doi.org/10.1016/j.eswa.2007.05.028.

D. Yarowsky. *Unsupervised Word Sense Disambiguation Rivaling Supervised Methods*. In *Proceedings of ACL*, pages 189–196, 1995. https://aclanthology.org/P95-1026/.

D.-H. Lee. *Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks*. ICML 2013 Workshop on Challenges in Representation Learning, 2013.

E. Arazo, D. Ortego, P. Albert, N. E. O'Connor, K. McGuinness. *Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning*. *arXiv preprint arXiv:1908.02983*, 2020. https://arxiv.org/abs/1908.02983.

A. Ratner, S. H. Bach, H. R. Ehrenberg, J. Fries, S. Wu, C. Ré. *Snorkel: Rapid Training Data Creation with Weak Supervision*. *Proceedings of the VLDB Endowment*, 11(3):269–282, 2017. https://arxiv.org/abs/1711.10160.

Q. Xie, M.-T. Luong, E. Hovy, Q. V. Le. *Self-Training with Noisy Student Improves ImageNet Classification*. In *Proceedings of CVPR*, 2020. https://arxiv.org/abs/1911.04252.

K. Sohn, D. Berthelot, N. Carlini, Z. Zhang, H. Zhang, C. A. Raffel, E. D. Cubuk, A. Kurakin, C.-L. Li. *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence*. In *Advances in NeurIPS*, 2020. https://arxiv.org/abs/2001.07685.

G. Hinton, O. Vinyals, J. Dean. *Distilling the Knowledge in a Neural Network*. *arXiv preprint arXiv:1503.02531*, 2015. https://arxiv.org/abs/1503.02531.

J. Gou, B. Yu, S. J. Maybank, D. Tao. *Knowledge Distillation: A Survey*. *International Journal of Computer Vision*, 129(6):1789–1819, 2021. https://arxiv.org/abs/2006.05525.

A. Joulin, E. Grave, P. Bojanowski, T. Mikolov. *Bag of Tricks for Efficient Text Classification*. In *Proceedings of EACL*, pages 427–431, 2017. https://aclanthology.org/E17-2068/.

N. Reimers, I. Gurevych. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019. https://arxiv.org/abs/1908.10084.

C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. *On Calibration of Modern Neural Networks*. In *Proceedings of ICML*, pages 1321–1330, 2017. https://proceedings.mlr.press/v70/guo17a.html.

Qwen Team. *Qwen3: Technical Report and Model Release*. GitHub repository and model documentation, 2025. https://github.com/QwenLM/Qwen3.

F. Gilardi, M. Alizadeh, M. Kubli. *ChatGPT Outperforms Crowd-Workers for Text-Annotation Tasks*. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120, 2023. https://doi.org/10.1073/pnas.2305016120.

P. Törnberg. *ChatGPT-4 Outperforms Experts and Crowd Workers in Annotating Political Twitter Messages with Zero-Shot Learning*. *arXiv preprint arXiv:2304.06588*, 2023. https://arxiv.org/abs/2304.06588.

T. G. Dietterich. *Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms*. *Neural Computation*, 10(7):1895–1923, 1998. https://doi.org/10.1162/089976698300017197.

J. Demšar. *Statistical Comparisons of Classifiers over Multiple Data Sets*. *Journal of Machine Learning Research*, 7:1–30, 2006. https://jmlr.org/papers/v7/demsar06a.html.

B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, London, 1993.

Q. McNemar. *Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages*. *Psychometrika*, 12(2):153–157, 1947. https://doi.org/10.1007/BF02295996.

csuldw. Moviedata-10M: a large-scale Douban movie dataset (140,502 films, 4,428,475 comments, collected 2019). AntSpider project, Central South University, 2019. https://github.com/csuldw/AntSpider. Research use only; the raw corpus is not redistributed here.