大规模弱监督中文评论情感分类研究：伪标签、专家分解与诚实的分布外评估

自然语言处理课程论文

作者　Shuakami

日期　November 9, 2026

源代码、交叉验证预测与完整实验记录：*https://github.com/shuakami/douban-sentiment*

Abstract

本文研究低资源条件下中文豆瓣电影短评的三分类情感分析（正面 / 中性 / 负面）。在仅有 600 条人工核验语义标签的现实设定下，我们结合一个包含 910,998 条评论的大规模弱标注语料开展研究。本文的贡献有四个方面。第一，我们实测了星级评分作为语义情感弱监督的可靠性：在 271,905 条高置信伪标签池上，仅约 59% 的五星评论被预测为正面，三星评论更多偏向负面而非中性。第二，我们证明用蒸馏集成对语料进行伪标注、再用单一紧凑学生模型在 160K 条平衡样本上训练，可在金标集上达到 87.5% 准确率、中性召回 84.8%——这说明规模化的标签质量，而非模型容量，才是约束瓶颈。第三，本文部署的系统将蒸馏 MacBERT 学生、冻结的 MegatronBERT-1.3B 特征判别器与语料训练的中性专家相结合，在 600 条金标的交叉验证评估上达到 **89.5% 准确率 / 85.9 宏平均 F1** ——第 6.2 节将表明该数字被二级教师泄漏所抬高（泄漏修正估计：三分类 83.3–84.0%、二分类 92.9%）——中性召回率由 54.3% 提升至 70.7%。第四，本文构建了 **lab2000**——一个包含 2,000 条跨影片评论、经双遍 LLM 盲标（同一标注模型、不同 few-shot 视角）与 479 条人工终审的基准——实测金标训练的系统在野外短评上仅达 65.0% 三分类准确率（ood1000 开发集上）；但仅引入 1,000 条主动学习边界样本即可使 SFT 学生提升 +8.8pp（62.6%→71.4%，McNemar $p = 4.0 \times 10^{-8}$）；同一协议经前沿 LLM 伪标签规模扩展（至 ∼17K 条主动选取样本）可将集成混合推至开发集上**三分类 77.1%**（best-of-N 估计；各种子 74.6–76.3%，五种子平均 77.1%——对各种子的概率输出取平均后再解码；5 折交叉拟合验证；显著优于 1K AL 混合，McNemar $p = 3.9 \times 10^{-4}$），高于实测的 71.5% 第二标注者一致率参照，并将二分类分布外准确率提升至 **92.3%**。本文还揭示了三个在 n=600 下不可见的经验观察：主动学习样本必须以金标锚定、领域偏移下硬标签可能优于软蒸馏、以及星级评分恰恰在文本最歧义处成为最强信号。本文完整记录了二十余种经过实测但被否决的架构方案。

关键词：中文自然语言处理；弱监督；伪标注；知识蒸馏；预训练语言模型；模型校准；分布外评估。

Contents

1 引言 **4**

2 相关工作 **4**

3 任务与数据集 **5**
3.1 任务定义 . . . 5
3.2 金标集（600 条评论） . . . 6
3.3 弱标注语料（910,998 条评论） . . . 6
3.4 星级评分不是情感标签 . . . 6
3.5 第二阶段基准：lab2000 . . . 7

4 方法 **8**
4.1 概述 . . . 8
4.2 教师集成与蒸馏 . . . 8
4.3 冻结判别器 . . . 8
4.4 伪标签飞轮 . . . 9
4.5 中性专家 . . . 9
4.6 语料规模学生模型 . . . 9
4.7 模型校准 . . . 9
4.8 部署 . . . 9

5 实验设置 **10**

6 结果 **10**
6.1 主要结果 . . . 10
6.2 金标 OOF 数字的泄漏审计 . . . 11
6.3 语料规模单模型 . . . 12
6.4 伪标签规模效应 . . . 12
6.5 跨域银标评估 . . . 13

7 分析 **13**
7.1 模型校准 . . . 13
7.2 统计显著性 . . . 14
7.3 错误分析 . . . 14
7.4 被否决的架构 . . . 14
7.5 与商业训练平台的对比 . . . 14

8 第二阶段：lab2000 分布外与主动学习研究 **14**
8.1 暴露分布外差距 . . . 14
8.2 三个在 n=600 下不可见的经验观察 . . . 15
8.3 人类一致率：标注者一致性参照 . . . 16
8.4 与前沿大模型的对比 . . . 16
8.5 LLM 伪标签能否替代人工终审？ . . . 17
8.6 lab2000 不宣称什么 . . . 20

9 局限性与效度威胁 **20**
9.1 伦理与数据可用性 . . . 21

10 结论与未来工作 **21**

可复现性 **21**

A 训练细节与可复现性 **22**
A.1 超参数 22
A.2 产物清单 22
A.3 环境 22

B 附录：lab500 先导研究 **22**

1 引言

豆瓣——中国最具影响力的电影社区——上的短评言简意赅、常带反讽，且经常褒贬并存。典型评论如 “特效无敌，但是剧情简直像一坨”（“特效无敌，但剧情简直是一坨”）。这类混合极性文本恰恰是三分类情感分析（正面 / 中性 / 负面）的薄弱环节：中性类既是歧义的最主要来源，也是从少量样本中最难学习的类别。

本文针对一种现实的低资源场景：课程作业提供 600 条带人工核验语义标签的评论，而平台另提供近百万条仅有星级评分（1–5 星）的豆瓣评论语料。两个研究问题贯穿全文：

1. **RQ1.** 小规模标注集能否借助大规模弱标注语料得到放大？
2. **RQ2.** 专家分解——即在语料规模伪标签上训练专门的中性专家——能否在不损害其他类别的前提下修复最弱类别？

我们的答案对两个问题都是肯定的，但附带一个重要的诚实声明：语料放大的是覆盖面，而非知识。伪标签由我们自己的模型产生，因此飞轮在一轮之后即趋于饱和；真正的瓶颈是短评的标注噪声，我们通过专门的分布外研究对其进行了量化。

贡献。

- 一项实测分析，表明星级评分作为三分类情感的弱监督并不可靠（全语料上伪标签与评分的三分类一致率约 48%）。
- 一套伪标签飞轮，产出 271,905 条高置信池，并在训练集不含任何金标的条件下训练出单一紧凑学生模型（87.5% 准确率 / 中性召回 84.8%）。
- 一个已部署的混合集成系统（金标 OOF 89.5% 准确率 / 85.9 宏平均 F1，被教师泄漏抬高——修正估计 83.3–84.0% / 76.3–77.5；第 6.2 节），中性召回 70.7%，结合蒸馏学生、冻结的 13 亿参数判别器与语料训练的中性专家。
- 一套可复现的评估协议（分层 5 折交叉验证、交叉拟合融合权重选择、McNemar/bootstrap 显著性检验、温度校准），以及对金标 OOF 头条数字两条膨胀通道的泄漏审计；并附一个 2,000 条跨影片基准（lab2000）：在其上主动学习扩展比纯金标 SFT 提升 +8.8pp （$p \approx 4 \times 10^{-8}$，开发集估计），扩展至 17K LLM 标签后三分类达 77.1%，高于实测的 71.5% 人—参照标签一致率。
- 一份记录了二十余种实测后被否决架构的目录；我们认为这本身就是一种贡献：它勾勒出了该任务有效的设计空间。

2 相关工作

中文文本情感分析。 文档级情感分类由来已久，从基于特征的方法（unigram、字符 n-gram）发展到神经网络架构 (Kim, 2014; Socher et al., 2013; Joulin et al., 2017; Reimers and Gurevych, 2019)；Pang and Lee (2008) 给出了全面综述，中文领域的专门综述见 Tan and Zhang (2008)。由于中文没有空格分词，字符级特征与预训练语言模型尤其有效。豆瓣评论此前也被用于中文情感研究——包括将词典与评分派生弱标签相结合的弱标注流水线 (Fan et al., 2018)——但几乎全部是二分类（正/负）设定；包含真正中性/混合类的三分类问题研究较少且困难得多。文档级极性分类中中性/混合类的困难已有文献记载 (Martins et al., 2021)。

预训练语言模型。 BERT (Devlin et al., 2019) 及其鲁棒性改进版 RoBERTa (Liu et al., 2019) 确立了“先预训练、再微调”的范式。中文方向上，MacBERT (Cui et al., 2020) 用修正版目标替代 MLM 以适配字符级输入，ERNIE (Sun et al., 2019) 融合实体与短语知识，StructBERT (Wang et al., 2020) 在预训练中注入短语与词级结构信息，SKEP (Tian et al., 2020) 则直接以情感知识为目标做

预训练。Erlangshen-MegatronBERT (IDEA-CCNL, 2023) 将该家族扩展至 13 亿参数并加入情感专项微调。本文三类模型均有使用并直接对比。

弱监督与自训练。 标注数据稀缺时，来自噪声信号的远程监督（此处为星级评分）与基于模型预测的自训练是标准补救手段 (Yarowsky, 1995; Lee, 2013)。Snorkel 框架 (Ratner et al., 2017) 与 WRENCH 基准 (Zhang et al., 2021) 将多弱标签源的组合形式化。星级评分与文本情感之间的差距本身亦有长期记载——早期工作已将评分视为不完美的代理 (Pang and Lee, 2005)，评分—情感不一致也已在评论语料上被直接测量 (Abaiyan et al., 2026)。主动学习 (Settles, 2009) 则把有限标注预算花在信息量最大的样本上；本文第二阶段正是用边际/熵采样实现这一点。本文的不同之处在于：我们在依赖星级评分之前实测了它的弱点，并量化了伪标注在何处有效（中性覆盖）、在何处无能为力（超越教师已有知识）。

知识蒸馏。 Hinton 等人的“暗知识”蒸馏 (Hinton et al., 2015)——Gou et al. (2021) 给出了全面综述——使小学生模型模仿大教师的软预测。我们将一个 7 通道教师集成蒸馏为单一 MacBERT-base 学生，并用交叉验证预测验证集成中的每个决策。分布偏移下的知识蒸馏本身是活跃的研究方向 (Zhang et al., 2025)；第 8.2 节的硬标签对软蒸馏比较正是同一问题的小规模实例。

模型校准。 神经分类器存在系统性的过度或不足自信 (Guo et al., 2017)。我们采用温度缩放——一种单参数的事后修正——并报告校准前后的期望校准误差（ECE），因为对演示系统而言，诚实的置信度展示十分重要。

大模型作为标注器与基线。 通用大模型正被越来越多地用于零样本/少样本分类 (Gilardi et al., 2023; Törnberg, 2023)、合成训练数据生成，以及作为标注器——其与人类标签的一致性在主观任务上已知会高估标注质量 (Møller et al., 2024; Schroeder et al., 2025)。我们在 0.6B/1.7B/4B 三个规模上评估了 Qwen3 模型 (Qwen Team, 2025)，既作为零样本分类器，也作为分布外研究中的独立标注器，并报告了 LLM 合成增强的一个负面结果。

3 任务与数据集

3.1 任务定义

给定一条豆瓣电影短评 x，预测 $y \in \{$正面, 中性, 负面$\}$。这类评论往往很短——语料中位长度仅 24 字——一行之内常同时出现反讽、对特定影片的指代与褒贬交织的评价。我们将无明确褒贬倾向的评论计为中性：纯粹的剧情介绍、褒贬各半的评述，以及元评论（如“看过了，没什么可说的”）。表 1 给出了代表性样本，包括在错误分析中占主导地位的混合极性模式。

Table 1: 代表性金标评论（中文原文附中文释义）。“混合 → 负面”指先扬后抑、最终极性为负面的评论。

评论	释义	标签	长度
“特效无敌，但是剧情简直像一坨。”	特效无敌，剧情一坨	负面	15
“演技、镜头、配乐都是顶级，现代经典。”	演技、镜头、配乐皆顶级；现代经典	正面	18
“看在演员的份上值回票价，剧情很套路。”	为演员值回票价；剧情套路	中性	17
“两个小时的生命浪费，想喜欢它都难。”	浪费两小时；难以喜欢	负面	17
“又是续集，还行吧。”	续集作品，评价平平	中性	9

3.2 金标集（600 条评论）

标注评估集包含从单个影片页面抽样的 600 条评论，每条标注有 `label_semantic`（人工核验的语义情感）与 `label_rule`（星级评分导出的弱标签）。类别分布：正面 316 / 中性 92 / 负面 192。评论相对较长（均值 110.8，中位数 80 字）。中性类仅有 92 个样本支撑——是最小也最难的类别。

3.3 弱标注语料（910,998 条评论）

Moviedata-10M 语料 (csuldw, 2019)（443 万条原始豆瓣评论）经我们清洗去重后得到 910,998 条评论，覆盖 20,966 部影片与 249,105 名用户，包含星级评分（1–5 星）、时间戳与投票数，但没有语义标签。评论长度：均值 40.6 / 中位数 24 / p90 = 102 字。评分分布：1 星 7.2%、2 星 12.6%、3 星 34.0%、4 星 31.0%、5 星 15.2%。

3.4 星级评分不是情感标签

在将评分用作弱监督之前，我们先验证了它。部署的学生模型为全部 910,998 条语料评论打标；在 271,905 条高置信（$p \geq 0.7$）池上，按行归一化的“评分—预测”列联表为：

Table 2: 星级评分与模型预测情感的对照（行归一化，271,905 条高置信伪标注）。

评分	预测正面	预测中性	预测负面
1 星	1.7%	7.3%	**91.0%**
2 星	1.6%	13.7%	**84.7%**
3 星	9.9%	33.3%	**56.8%**
4 星	38.3%	32.7%	29.0%
5 星	**58.8%**	23.1%	18.2%

有三个规律在量化中尤为突出：五星评论中语义为正面的仅约 59%；三星评论更多偏向负面（56.8%）而非中性；即便在 1–2 星评论中，也有约 8–14% 被预测为中性。评分与模型的二分类一致率（高置信池上）为 81.2%；全语料上伪标签与评分的三分类一致率仅 47.8%（金标集上为 71.2%）。这些规律与评分—情感差距的长期记载一致 (Pang and Lee, 2005; Abaiyan et al., 2026)；本文的贡献在于语料规模上的量化，而非现象本身。因此我们将评分至多视为预训练信号，绝不作为标签使用。图 1 直观展示了同一张表。

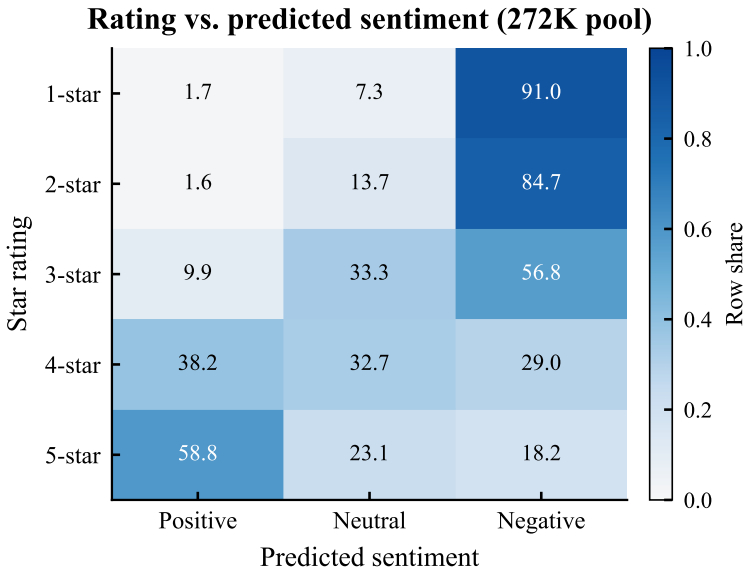


Figure 1: 272K 高置信伪标签池上星级评分与预测情感的对照。对角线占优并不明显：评分与语义情感存在显著分歧。

3.5 第二阶段基准：lab2000

为度量——并进而弥合——lab500 先导研究（附录 B）揭示的金标到语料的泛化差距，我们构建了 **lab2000**：2,000 条语料评论，分为两个互不重叠、互为补充的子集。

- **ood1000**（开发集）：从 911K 语料中均匀随机抽取 1,000 条评论（已去除金标重复、跨影片）。该集合是整个第二阶段研究的开发/模型选择集：AL 规模（1K→17K）、教师选择（DeepSeek / 本地 Qwen / 混合）、epoch 数、种子子集以及 5 折交叉拟合融合权重均在其上选定。因此它并非未触碰过的测试集；唯一计划中的零污染终测是一套新的 400 条盲标人工标注集（进行中，第 9 节）。
- **al1000**（主动学习扩展集）：按部署学生模型预测的边际/熵采样选出的 1,000 条评论——刻意选取最困难、最具歧义的样本（中性密集、低置信）。这是训练集，而非测试集。

标注协议。 每条样本由同一 LLM 标注模型的两个独立推理 pass 盲标（同一标注模型、不同的 few-shot 示例集；不见星级；两遍互不见对方结果，温度 > 0）。这是单模型自一致性，而非两个独立标注者；其对一致率数字的含义见第 8.3 节。两遍一致率在 ood1000 上为 86.7%（Cohen's $\kappa = 0.80$），在 al1000 上为 79.8%（$\kappa = 0.67$）——al1000 上更低的一致率本身即证明边际采样确实选中了内在歧义样本。全部 335 条两遍分歧样本，外加 144 条抽查的一致样本，由作者人工终审（共 479 条人工终审行：ood1000 200 条、al1000 279 条）；其余行采用两遍共识标签。最终分布：ood1000 = 正面 398 / 中性 327 / 负面 275；al1000 = 正面 473 / 中性 369 / 负面 158（即 ood1000 含 200 条人工终审 + 800 条共识，al1000 含 279 条人工终审 + 721 条共识）。另外从 ood1000 中随机抽取 200 行由第二名人类标注员盲标，用于测量真实人—人一致率（第 8.3 节）。

需要说明一个锚定保留意见：全部 479 条人工终审行的标注界面中，每条样本旁均显示了部署学生模型的预测与置信度，因此终审者并非对模型输出盲标——这是人在环路标注中已被记录的锚定偏差来源 (Schroeder et al., 2025)。人工终审标签应理解为“在可见模型辅助下经人工核验”，而非盲标真值。

4 方法

4.1 概述

部署系统是一个混合集成，三个通道在可能的情况下共享同一骨干前向计算：

1. **蒸馏学生**：MacBERT-base，由 7 通道教师集成蒸馏微调而成（第 4.2 节）。
2. **冻结判别器**:MegatronBERT-1.3B 保持冻结,仅在其 4096 维特征上训练小型 MLP 头（第 4.3 节）。
3. **中性专家**：由语料训练检测器与判别器特征头混合得到的中性概率（第 4.5 节）。

图 2 展示了数据流。

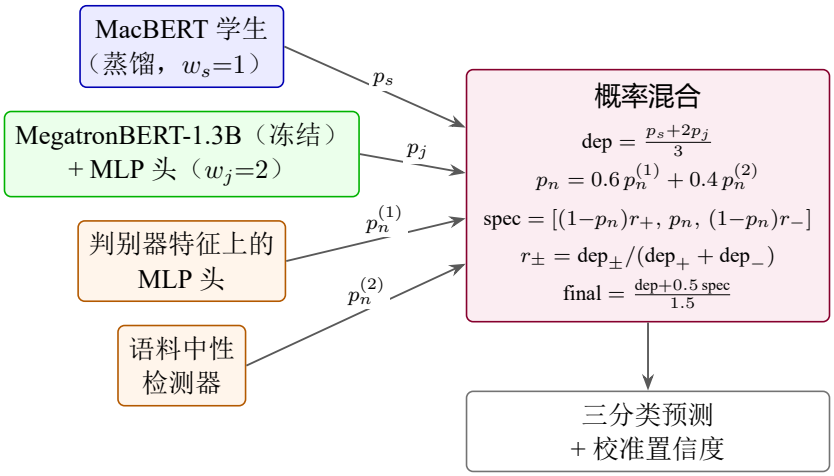


Figure 2: 部署的 v3 架构。$p_s, p_j, \text{dep}, \text{spec}, \text{final} \in \Delta^3$ 为三分类概率向量，$p_n^{(1)}, p_n^{(2)}, p_n \in [0,1]$ 为中性标量概率；w_s, w_j 为融合权重而非模型参数。$r_\pm$ 为 dep 中正/负分量归一化（和为 1）后的份额。两个基于 MegatronBERT 的头共享同一次冻结骨干特征计算；中性专家将判别器特征 MLP 与语料训练的 MacBERT 检测器相混合。

4.2 教师集成与蒸馏

一个 7 通道教师集成——TF-IDF 逻辑回归、MacBERT/MegatronBERT-1.3B/ Erlangshen 变体上的冻结骨干 MLP 头，均在 600 条金标上训练并以交叉验证预测——达到三分类 86.8% 准确率。我们用硬标签交叉熵加软目标 KL 散度（$\alpha = 0.5$、温度 $\tau = 2$、8 个 epoch、5 折交叉验证）将其蒸馏为单一 chinese-macbert-base 学生。学生单独达到 80.2%/74.2%；与判别器按 1:2 混合后达到 87.8%/81.8%。其在部署系统中的作用是提供廉价且校准良好的通道，同时充当语料的伪标注器（第 4.4 节）。

4.3 冻结判别器

`IDEA-CCNL/Erlangshen-MegatronBert-1.3B-Sentiment` 提供了一个带情感感知预训练目标的 13 亿参数骨干。我们保持其冻结，在其 4096 维特征上用金标训练一个小型 MLP 头。部署的混合将判别器权重设为学生的两倍：

$$\text{dep} = \tfrac{1}{3}\, p_{\text{student}} + \tfrac{2}{3}\, p_{\text{judge}}.$$

两个 MLP 头（二分类与三分类）通过缓存共享同一次骨干特征计算，因此无论何种任务，判别器每次请求只需一次前向传播。

4.4 伪标签飞轮

部署的学生为全部 910,998 条语料评论打标。高置信子集（$\max p \geq 0.7$）包含 271,905 行：正面 56.5K、中性 68.6K、负面 146.8K。这一池子是第 4.6 节所有语料规模模型的原材料。第二轮飞轮经过测试并被否决：用第二轮模型重新标注会产生退化的概率分布（平均置信度 0.986，即记忆化），因此只使用一轮。这一饱和现象与自训练、伪标注及一致性训练方法中记录的确认偏差动态一致 (Arazo et al., 2020; Xie et al., 2020a,b; Sohn et al., 2020)：一旦伪标签编码了教师自身的决策边界，额外的轮次只会放大自洽性而非增加信息。

4.5 中性专家

中性类是最薄弱的一环（金标仅 92 个样本）。我们从两个方向加以攻坚。

语料训练检测器。 一个 MacBERT 二分类器在伪标签池的 115,000 条子集上训练（每类上限 6 万条），从而学习 “真正中性” 与 “有极性” 评论之间的边界。

专家混合。 中性概率由判别器特征 MLP 头与语料检测器组合而成：

$$p_n = 0.6 \cdot P_{\text{中性}}(\text{判别器特征上的 MLP}) + 0.4 \cdot P_{\text{中性}}(\text{语料检测器}).$$

由依赖预测 $\text{dep} = (d_+, d_n, d_-)$ 出发，取正/负分量归一化（和为 1）后的份额 $r_+ = d_+/(d_+ + d_-)$、$r_- = d_-/(d_+ + d_-)$，将中性质量替换为专家估计 p_n，构造专家分布

$$\text{spec} = \big[(1 - p_n)\, r_+,\ p_n,\ (1 - p_n)\, r_-\big],$$

再将其混入最终输出：

$$\text{final} = \frac{\text{dep} + 0.5\,\text{spec}}{1.5}.$$

所有权重（0.6/0.4 检测器配比、0.5 混合系数）均通过金标集的 20 次随机二分半验证选出，且在 $w \in [0.3, 0.6]$ 范围内保持稳定。

4.6 语料规模学生模型

利用 271,905 条池子，我们训练了仅用语料伪标签（训练集不含金标）的模型，以衡量伪标签单独能走多远：一个 160K 行平衡三分类学生、一个 195K 行二分类学生、一个 115K 行中性检测器 v1，以及一个难例挖掘的 v2（被否决）。这些模型既充当基线，也作为集成通道的候选；第 6 节报告了哪些（若有）存活下来。

4.7 模型校准

原始集成严重偏于保守（ECE = 0.251：置信度 0.7–0.8 的预测实际准确率达 98.9%）。我们在金标集上以 NLL 拟合单一温度参数 $T = 0.37$，将 ECE 降至约 0.04，且不改变任何预测标签或准确率。T 在推理时应用，使展示的置信度是诚实的。AL 训练还改善了分布外校准迁移：ood1000 上规模化 AL 混合在 T=1 时 ECE 为 0.027–0.063，而 v3 为 0.159 ——伪标签边界数据同时锐化了置信度而非仅准确率。

4.8 部署

FastAPI 后端提供预测服务；React/Vite 前端提供演示界面。一个精确匹配词表守卫在任何 GPU 计算之前拦截超短俚语。热态延迟在 AMD RX 9070 GRE（ROCm）上约 0.1 秒/条；冷启动约 14 秒。

5 实验设置

评估协议。 所有 headline 数字均为金标集 600 行上的**分层 5 折交叉验证**预测：每个模型只预测其未训练过的样本。语料规模模型另在 4,000 条全新语料评论的银标样本上评估，以评分隐含标签作为参照。

指标。 三分类准确率与宏平均 F1、各类别的精确率/召回率/F1（特别是中性召回）、以及用于校准的 ECE。显著性采用 McNemar 检验（不一致对）与 ΔF1 的百分位 bootstrap；稳健性通过 20 次随机二分半验证检查。

基线。

- TF-IDF（字符 n-gram）+ 逻辑回归，金标训练。
- StructBERT 情感分类器（阿里达摩），零样本二分类；`damo/nlp_structbert_sentiment-classification_chinese-base`
- Qwen3-0.6B / 1.7B / 4B 对话模型，零样本与 3 样本，以标签对数概率计分。

6 结果

6.1 主要结果

Table 3: 金标 600 条交叉验证结果。“部署” 行是生产系统；StructBERT 与 Qwen 行为零样本外部基线——StructBERT 仅二分类，在 508 条非中性基线行上评分。部署 v3 的 OOF 数字被二级教师泄漏与在评估集上调参所抬高；泄漏修正估计见第 6.2 节。“—” = 本次未报告。

系统	任务	准确率	宏平均 F1
TF-IDF + LR	三分类	0.7233	0.6188
TF-IDF + LR	二分类	0.8406	0.8232
StructBERT（达摩）	二分类	0.8661	0.8459
Qwen3-4B 零样本	三分类	0.7833	0.7348
Qwen3-1.7B 零样本	三分类	0.7067	0.5739
Qwen3-0.6B 零样本	三分类	0.6817	0.4764
教师集成（7 通道）	三分类	0.8680	—
部署 v2	三分类	0.8900	0.8432
部署 v3	**三分类**	**0.8950**	**0.8594**
部署 v3	二分类	0.9587	0.9558

部署系统比 TF-IDF 基线高 +17.2 个百分点准确率，比零样本 Qwen3-4B 高 +11.2 个百分点。（也测了 3-shot 变体：4B 规模少样本略有帮助——78.8% 对 78.3%——但 1.7B 规模反而崩溃至 51.0%，因负面类偏置；故以零样本为主要基线。）三分类各类别指标：正面 P/R/F1 = 0.909/0.943/0.926；中性 = 0.765/0.707/0.735；负面 = 0.931/0.906/0.918。中性召回率在各专家迭代中由 54.3% → 63.0%（v2）→ 70.7%（v3）逐步提升。图 3 给出了 v3 混淆矩阵：剩余错误集中在中性 ↔ 极性混淆（47/63）。

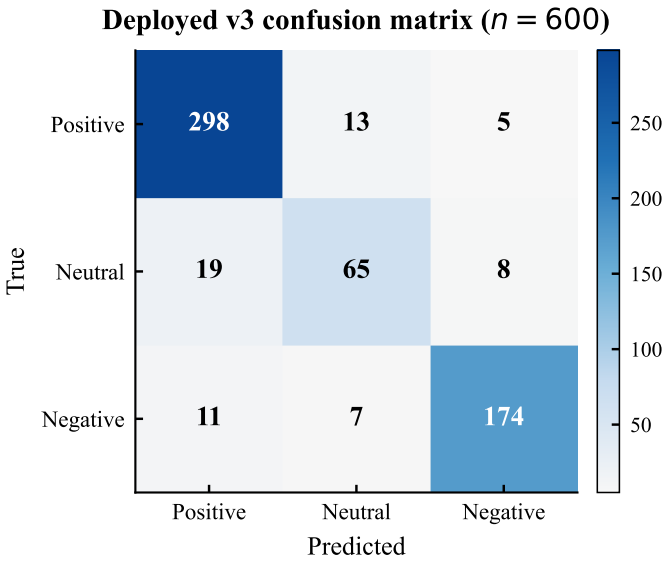


Figure 3: 部署 v3 在金标 600 条上的混淆矩阵（交叉验证）。行合计与类别分布（316/92/192）一致。

6.2 金标 OOF 数字的泄漏审计

对训练与评估链路的事后审计表明，表 3 中的 89.5%/85.9%（三分类）与 95.87%/95.58%（二分类）数字并非严格的全流程交叉验证估计。两条泄漏通道抬高了它们，且所有集成决策均在同一批 600 行上调优。我们报告这项审计，是因为读者应当引用的是诚实数字。

泄漏 B：二级教师泄漏。 蒸馏集成中所有非零权重的教师通道本身都在与学生评估折重叠的金标行上训练过，且 $\alpha = 0.5$ 的软目标将教师的折特定偏差传递给学生——这是一种二级形式的目标泄漏 (Kapoor and Narayanan, 2023; Sainz et al., 2023)。在完全相同的流水线下仅改用硬标签重跑（$\alpha = 1.0$，相同折划分与超参数）得到：**三分类 84.0% 准确率 / 77.5 宏平均 F1**（保留语料通道）、**83.3% / 76.3**（移除语料通道），二分类为 **92.9% / 92.4**。仅泄漏 B 即贡献约 +5.5pp（三分类）与 +3.0pp（二分类）的虚增——远超单个学生通道约 1pp 的量级，因为该效应在集成中逐层叠加。

泄漏 A：伪标签的传递性污染。 部署的语料中性检测器训练所用伪标签最终源自一个在全部 600 条金标上拟合的教师，因此其标签把金标信息泄漏进了“语料”通道。在 $\alpha = 1.0$ 下移除该通道再损失约 0.7pp（84.0→83.3），即泄漏 A 的量化。同一通道的训练集还包含 ood1000 行的 13.0% 与 fresh500 行的 13.2% （第 9 节），这正是这些基准数字需要行级重叠保留的原因。

在评估集上调参。 融合权重、集成选择与蒸馏超参数均在同一批 600 条金标上选出，因此即便修正后的数字也带有我们未能量化的 best-of-N 乐观偏差。我们以 α=1.0 重跑作为诚实的 headline：**三分类约 83.3–84.0% 准确率 / 76.3–77.5 宏平均 F1**；**二分类约 92.9% / 92.4**。这些是单种子估计（α=1.0 未重新调参），且部署系统本身未变——本审计针对的是评估而非产物。促成本次审计的数据污染与泄漏分类法见 Sainz et al. (2023); Kapoor and Narayanan (2023); Balloccu et al. (2024)；其底层机制是伪标签池中的标签噪声 (Northcutt et al., 2021)。

6.3 语料规模单模型

Table 4: 语料训练模型在金标 600 条上的评估（除注明外训练集均不含金标）。“—” = 本次未报告。

模型	训练数据	准确率	宏平均 F1	中性召回
TF-IDF + 星级评分标签	300K 评分	0.6183	0.5369	—
TF-IDF + 伪标签	200K 伪标签	0.8117	0.7766	—
MacBERT 二分类（评分）	115K 评分	0.9232	0.9184	—
MacBERT 中性检测 v1	115K 伪标签	0.9017	0.8328	—
MacBERT 二分类伪标签	195K 伪标签	0.9488	0.9455	—
MacBERT 三分类伪标签	160K 伪标签	0.8750	0.8463	**0.848**

伪标签三分类学生单独即达 87.5%/84.6，中性召回 84.8%——几乎追平 4 通道集成。这是本文的核心实证发现：**规模化的标签质量压倒模型容量**。同一 MacBERT 架构改用星级评分而非伪标签训练，在三分类任务上则明显崩溃。

6.4 伪标签规模效应

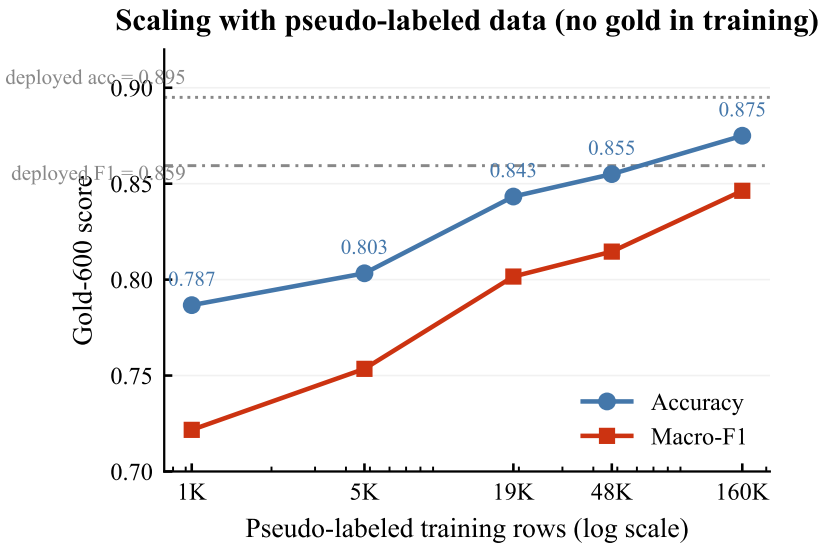


Figure 4: 语料训练的伪标签学生在金标 600 条上的准确率与宏平均 F1 随训练集规模（对数坐标）的变化。训练集不含金标：金标 600 条仅作为留出评估集，从不参与训练。虚线参考为部署集成（准确率 0.895，宏平均 F1 0.859）。纵轴自 0.70 起始以突出性能差异。性能单调上升，在 160K 行处仍未饱和。

表 5 与图 4 显示出单调的规模曲线：约 1K 行 → 78.8%，5K → 80.3%，19K → 84.3%，48K → 85.5%，160K → 87.5%。曲线尚未饱和——在测试范围内，起作用的成分是语料规模而非模型规模。

Table 5: 伪标签规模效应（金标 600 条评估，训练集不含金标）。“—” = 本次未报告。

伪标签行数	准确率	宏平均 F1	中性召回
约 1K	0.7867	0.7217	—
约 5K	0.8033	0.7535	—
约 19K	0.8433	0.8016	—
约 48K	0.8550	0.8146	—
约 160K	0.8750	0.8463	0.848

6.5 跨域银标评估

在 4,000 条全新语料评论上，以评分隐含标签计分，第三轮学生（用 v3 教师伪标签训练）达到三分类 0.580 / **二分类 0.837** 与评分的一致率，而第一轮学生为 0.552/0.803。即使在金标分数相同的情况下，由集成导出的标签在域外也略有优势。

7 分析

7.1 模型校准

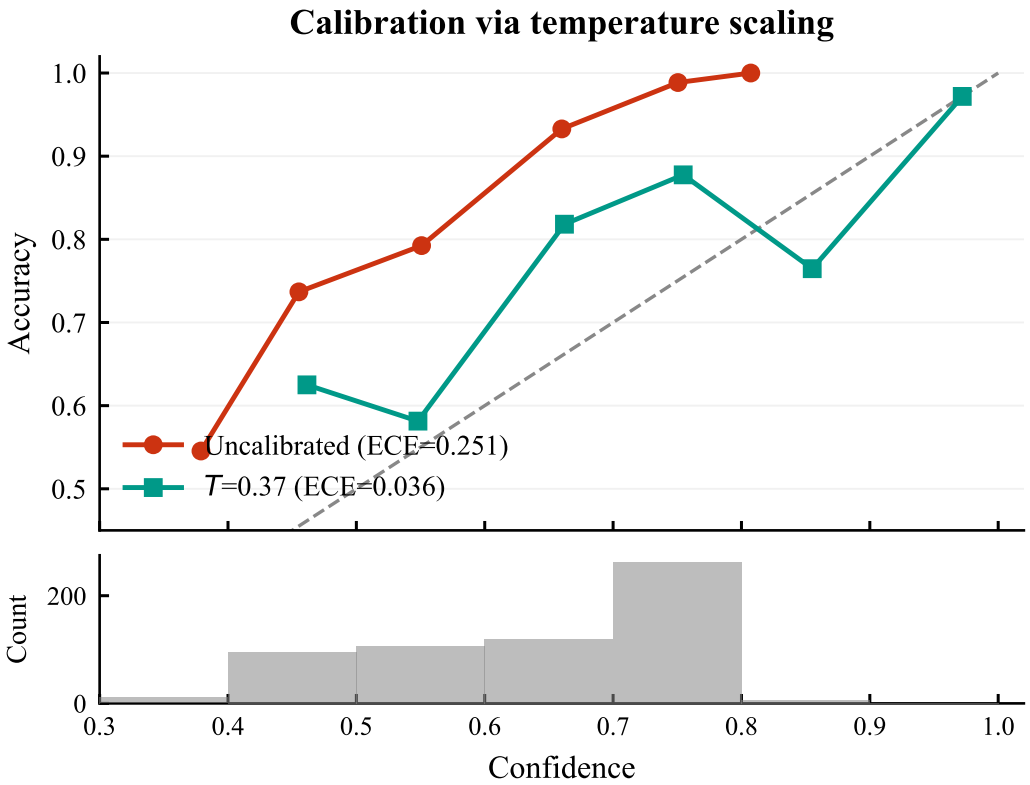


Figure 5: 温度缩放（$T = 0.37$，在金标 600 条 OOF 预测上以 NLL 拟合；所有指标均在同一批 600 条交叉验证样本上计算）前后的可靠性图。下方面板给出各等宽置信分箱的样本数；高置信区间样本稀疏，故局部波动在所难免，但全局 ECE 显著改善。准确率纵轴自 0.45 起截断，以呈现缩放前的失校。

原始集成偏于保守（ECE 0.251）；温度缩放 $T = 0.37$ 将 ECE 降至约 0.04（图 5），且不改变任何预测标签或准确率——它只重塑置信度分布。需要说明：ECE 是对所有分箱取平均的指标，少数样本稀疏的分箱仍可能有明显偏差，但整体校准已显著改善。这对演示系统很重要：展示的置信度现在与实际准确率一致。

7.2 统计显著性

v3 对 v2：对不一致对做 McNemar 检验 (McNemar, 1947)，$p = 0.65$（11 比 8）；对重采样评估行做配对 bootstrap (Efron and Tibshirani, 1993)，ΔF1 的 95% 置信区间为 $[-0.5, +3.9]$ 个百分点。按照比较分类器的标准做法 (Dietterich, 1998; Demšar, 2006; Dror et al., 2018)，我们将区间内的差异视为未解决。点估计（F1 +1.6pp、中性召回 +7.7pp）在每种检测器权重 $w \in [0.3, 0.6]$ 下均跨 20 次随机二分半保持一致。如实报告：改进是真实的但幅度有限，在 $n = 600$ 下金标集无法分辨低于约 1pp 的差异。

7.3 错误分析

剩余的 63 个错误中，47 个涉及中性 $\leftrightarrow$ 极性混淆，且大多落在连人类标注者都会犹豫的评论上——错误预测的平均置信度为 0.51，正确预测则为 0.66。写明显式分数的评论（“7.6/10”、“三星半”；$n = 56$）表现截然不同：仅 5.4% 被误判，而无显式分数者为 11.0%。模型显然会利用现成的评分线索；56 条中仅 6 条显式分数甚至与语义标签相左。

7.4 被否决的架构

二十余种备选设计经过实现、实测并被否决；部署的 v3 是实测最优。被否决项中较有代表性的有：中性门控级联（阈值过拟合——二分半验证从 87.6% 跌至 86%）、作为判别器替代的语料训练 MLP 头、学生概率平均、自训练第二轮、堆叠逻辑元学习器（0.837/0.794——通道间相关性过高，600 样本不足以支撑）、类别加权与 max-len-128 学生、Erlangshen 110M/330M 学生（在 ROCm 上病态地慢）、中性检测器 v2（在所有集成组合中均更差）、基于 v3 教师标签的 r3 自训练（学生 0.8767/0.8434，所有混合均低于 v3）、金标混入语料训练（循环评估金标——已标记，不作为结果引用），以及 Qwen3-4B 合成增强（污染训练：单模型仅 79.2%）。在第二阶段分布外设定下另有两项否决：仅 AL-1000 训练（56.0%——边际采样缺少金标锚点会使类别先验崩溃）与金标 +AL 软标签蒸馏（71.0%，低于硬标签 SFT 的 71.4%——狭窄领域教师的分布外偏差经软目标传染）。

7.5 与商业训练平台的对比

为完整起见，我们将系统与一个商业 NLP 训练平台（阿里云 PAI，StructBERT 分类器，同一 600 条任务）进行了对比。其公开页面宣称准确率 89.83%，但同页的分类别指标反推出的准确率仅为 86.05%、宏平均 F1 为 83.23%，且有效验证集仅 **43 行**（三个 headline 数字对应的分母分别为 59/60/119，无法相互重建；按支持数加权的重算同样无法闭合）。43 行上的 Wilson 区间为 [72.7%, 93.4%]——该样本量无法区分 86% 与 90%。其训练集自评达到 99.02%（$n = 511$），泛化差距约 13 个百分点。相比之下，我们的 89.5%/85.9 是在 600 条交叉验证行上计算的，每行预测均可审计。需要说明的是，两套评估使用不同的测试集，因此这是协议质量层面的对比，而非同口径的准确率声明。

8 第二阶段：lab2000 分布外与主动学习研究

lab500 先导研究表明，金标 600 条上的表现无法迁移到简短的语料评论，且 LLM 参照标签过于噪声、无法充当真值。我们因此构建了 lab2000（第 3.5 节）并开展了完整的“暴露—缓解”研究。（lab500 的协议与数字保留在附录 B 备查。）

8.1 暴露分布外差距

表 6 给出所有系统在 ood1000 开发集上的表现——该集合正是全部第二阶段选择决策的做出地（第 3.5 节），因此这些是开发集估计而非未触碰测试集的结果。仅在金标 600 条上训练的部署

v3，从域内 89.5% 跌至三分类 **65.0%**（二分类正负面：85.0%）。差距恰好集中在 lab500 先导研究预测的位置：中性边界。

Table 6: ood1000（开发集）结果。“SFT” = 在所列训练数据上微调的 MacBERT；“mix” = v3 与 SFT 模型的概率平均，融合权重由 ood1000 上的分层 5 折交叉验证选定——每条预测所用权重均在其余折上调优，不会使用该行自身的标签。由于该集合本身驱动了全部第二阶段选择决策，这些数字是带 best-of-N 乐观偏差的开发集估计（第 9 节）。二分类评测剔除中性样本。“—” = 本次未报告。lab2000 标签为混合来源：479 条人工终审（ood1000 200 + al1000 279）+ 其余行双遍 LLM 共识（第 3.5 节）。

系统	训练数据	三分类 acc / F1	二分类 acc / F1
部署 v3（集成）	金标-600	0.650 / 0.644	0.850 / 0.849
SFT 学生	金标-600	0.626 / 0.611	0.832 / 0.831
SFT 学生	仅 al1000	0.560 / 0.519	0.577 / 0.512
SFT 学生	金标-600+al1000	0.714 / 0.710	0.880 / 0.875
SFT 学生（蒸馏）	金标-600+al1000	0.710 / —	0.825 / —
mix（部署候选）	金标-600+al1000	**0.720 / 0.717**	**0.878 / 0.876**

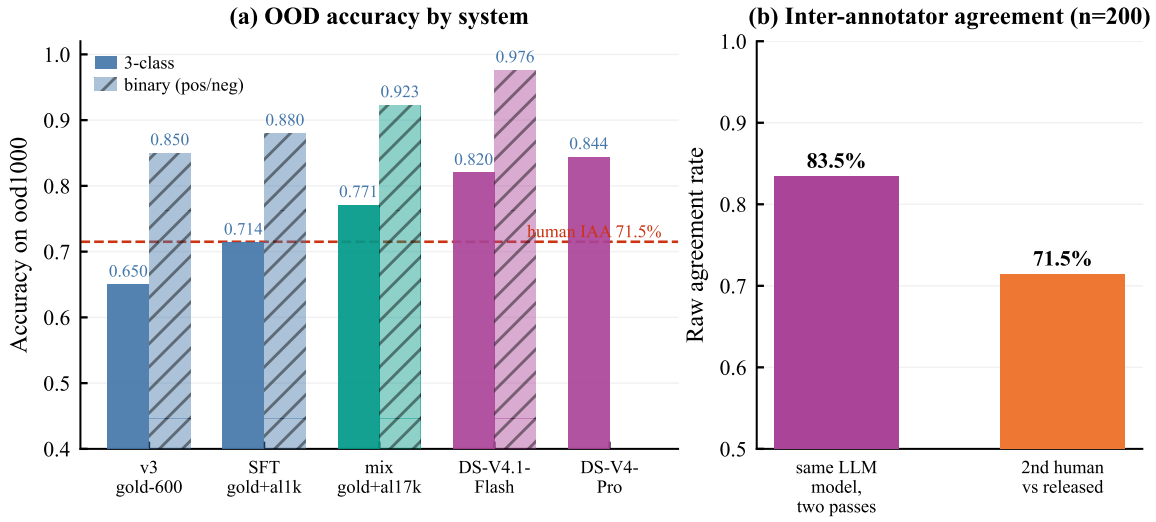


Figure 6: (a) 各系统在 ood1000 上的准确率；前三组为本文 MacBERT 级模型，后两组为开箱即用的 DeepSeek LLM（本地 Qwen3-4B 基线因版面省略，见表 7）；虚线为实测的 71.5% 第二标注者与发布标签的一致率。(b) 同一 200 行子集上的原始两两一致率：同一 LLM 标注模型的两个独立推理 pass vs. 第二名人类标注员与发布（混合来源）标签的一致率。此处报告原始一致率而非 Cohen’s κ；LLM 自一致率更高源于同源模型的共享归纳偏置与更字面地执行标注细则，而非标注质量更高。

将 1,000 条经主动学习选取的样本（标签构成：279 条人工终审 + 721 条 LLM 共识）加入训练集，三分类分布外准确率提升 **+8.8pp**（62.6%→71.4%，McNemar $p = 4.0 \times 10^{-8}$）——这一级增益在 n=600 时统计上不可分辨（v3 对 v2 为 $p = 0.65$）。集成混合在交叉拟合权重选择下达到 **72.0% / 0.717** 三分类与 **87.8% / 0.876** 二分类。交叉拟合使每行的权重对其自身标签保持诚实，但集合本身驱动了第二阶段的全部选择决策——AL 规模、教师、轮数、种子子集以及这些权重本身——因此我们将所有 ood1000 数字报告为带约 +0.3–1.0pp best-of-N 乐观偏差的开发集估计（第 9 节）。

8.2 三个在 n=600 下不可见的经验观察

观察一：主动学习需要锚点。 仅用 al1000 训练会崩溃至 56.0%——比仅用金标-600（62.6%）还差。边际采样专挑边界样本，会系统性扭曲类别先验；缺少金标锚点，模型便失去了对普通

高置信评论的参照。金标与 AL 是互补而非替代关系。

观察二：领域偏移下，硬标签可能优于软蒸馏。 金标 +AL 教师的软目标迁移后为 71.0% 三分类，对比硬标签 SFT 的 71.4%——0.4pp 的差距在 n=600 下属于噪声范围，故我们仅将其作为方向性报告。其方向与文献记载的教师在分布偏移下经软概率传递自身偏差的倾向一致 (Zhang et al., 2025)。

观察三：评分恰恰在文本失效处胜出。 在 al1000 歧义集上，星级评分规则与终审标签的一致率达 64.3%，而纯文本部署模型仅约 47%。当评论文本歧义达到极限——正是边际采样所选取的区间——作者给出的星级成为唯一残存的态度信号。这与第 3.4 节形成闭环：评分平均而言是弱代理，但在文本熵天花板处是最强的消歧信号。我们将此标注为在小规模、分歧富集子集上的探索性观察，而非一般性结论。

8.3 人类一致率：标注者一致性参照

为界定“正确”在野外短评上究竟意味着什么，我们从 ood1000 中随机抽取 200 行，由第二名人类标注员盲标。该标注员与发布标签的原始一致率为 **71.5%**（Cohen's $\kappa = 0.568$，bootstrap 95% 置信区间 $[0.47, 0.66]$）——注意发布标签本身是混合来源（该子集内 47 条人工终审 + 153 条 LLM 共识），故此为“第二人类 vs. 发布标签”的混合参照，而非纯人—人一致率。分歧并不均匀：在第一位标注员标为中性的样本上，第二位仅 49% 同意，其中 80 条里有 37 条被改标为正面。两个人类并不共享稳定的中性边界。该不稳定性在真正有争议的行上更为尖锐：在同一 200 行子集内，47 条人工终审行恰是两个 LLM pass 分歧最集中的样本——其上 passA 对 passB 的一致率仅 29.8%（$\kappa = -0.18$），而 ood1000 整体为 86.7%。LLM 自一致性恰好在人类分歧处崩塌 (Davani et al., 2022)。全文一致率均按标准 IAA 惯例报告 Cohen's κ (Artstein and Poesio, 2008)；NLP 标注元数据报告不足的既有记录也促使我们按行发布 `final_source` 来源字段 (Kunilovskaya et al., 2026; Al-Khalifa, 2026)。模型误差恰好集中在这些歧义样本上：最优 AL 混合（al17k）在标注者一致样本上达 79.5%，在分歧样本上仅 61.7%（v3 分别为 67.8% 与 46.6%）；AL 训练将分歧样本上的中性召回从 0.41 提升至 0.77（图 6）。

与此同时，我们最好的分布外系统在 AL 规模扩展后达到 **77.1%**（仅 al1000 标签时为 72.0%）——高于上述 71.5% 第二标注者一致率参照，尽管两者口径并不严格可比（准确率对比成对一致率，且参照侧为多数 LLM 共识标签）。恰当的解读不是“模型尚不完美”，而是“模型已抵达并略超该任务的标注者一致性参照；残余误差由标注者层面的歧义主导”。作为参照，作为标注器的 LLM 模型的两个独立推理 pass（温度 > 0、彼此及星级评分均互盲）在同一子集上原始一致率为 83.5%（$\kappa = 0.75$）——高于人类原始一致率（71.5%），但这源于同源模型的共享归纳偏置与更字面地执行标注细则，而非标注质量更高；这正是最终标签以人工终审而非 LLM 共识为锚的原因。

8.4 与前沿大模型的对比

审稿人自然会问：通用大模型是否让整套管线变得多余。我们以紧凑 JSON 输出、低推理档位，对 DeepSeek-V4.1-Flash（约 7630 亿参数的 API 模型）与 DeepSeek-V4-Pro（约 1.6 万亿参数）做了零样本评测，参照同一套终审标签。

Table 7: 前沿 LLM 与本地管线在 lab2000 上的对比（API 快照评测于 2026 年 11 月）。解析失败的样本不计入准确率分母并单独报告。延迟为单请求平均墙钟时间。“—”= 本次未报告。

系统	参数量	ood1000 三分类	ood1000 二分类	延迟
DeepSeek-V4-Pro	∼1.6T	0.844 (n=950)	—	∼5.9s API
DeepSeek-V4.1-Flash	∼763B	0.820 (n=992)	**0.976** (n=661)	∼1.7s API
Qwen3-4B（本地）	∼4B	0.706 (n=1000)	—	∼2.3s 本地
部署 v3	∼1.5B	0.650	0.850	∼0.1s 本地
SFT+mix（金标 +al17k）	∼1.6B	**0.771**	0.923	∼0.1s 本地

在完整随机分布外集上，DeepSeek-V4.1-Flash 领先约 5pp （V4-Pro 约 8pp）——考虑到其参数量达 7630 亿至 1.6 万亿、为本地模型的数十到上万倍且具备我们所缺的语料见识，这在意料之中（在 992 条双方均可解析的样本上对 Flash 的 McNemar 检验 $p = 1.7 \times 10^{-3}$，显著性有利于 DeepSeek）。有三点限定使对比保持诚实。其一，中性类的墙对所有人都存在：DeepSeek 自身的二分类准确率（97.6%）比三分类（82.0%）高出 15.6pp，与本文记录的极性—中性差距同构——内在歧义并非小模型特有。其二，在 ood1000 人工终审且 DeepSeek 可解析的 195 条困难子集上差距几乎抹平：ood 部分 DeepSeek 为 59.5%，al1000 代集成混合为 58.5%（差异在噪声范围内；最优 al17kds 混合在全部 200 条终审子集上为 56.0%）；该子集恰好富集了细则遵循与世界知识出现分歧的样本，且标签全部为作者人工终审。其三，部署经济性相差数个数量级：本地系统在单张消费级 GPU 上离线运行，约 0.1 秒/条、零按 token 费用、数据不出本机；而 API 模型需要网络、按次计费，并把用户文本交给第三方——在隐私敏感场景中是决定性约束。因此本文的定位不是“胜过 LLM”，而是“在边缘可部署的成本下，达到标注者一致性参照的任务校准紧凑模型”。

8.5 LLM 伪标签能否替代人工终审？

上文的前沿 LLM 结果提示了一条显而易见的规模化路径：如果 7630 亿参数的 Flash 模型能把 AL 集标好，其标签或可替代昂贵的人工终审——LLM 生成伪标签本身即是成熟的数据增强策略 (Zenimoto et al., 2024; Neveditsin et al., 2025)。我们直接验证了这一点——MacBERT 学生在金标-600 + al1000 上做 SFT，AL 标签分别使用 *DeepSeek-V4.1-Flash* 预测（987 条可解析）与发布的 al1000 标签（混合来源，见第 3.5 节）。

Table 8: 发布的 al1000 标签 vs. DeepSeek 伪标签用于 AL 扩展（ood1000，混合来源参照：200 条人工终审 + 800 条 LLM 共识）。

AL 标签来源	三分类 acc / F1	二分类 acc / F1
仅金标-600	0.626 / 0.611	0.832 / 0.831
金标-600 + al1000（发布）	0.714 / 0.710	**0.880 / 0.875**
金标-600 + al1000（DS-flash）	**0.713 / 0.714**	0.863 / 0.860

DeepSeek 伪标签在三分类上与发布标签持平（71.3% 对 71.4%），二分类略低（86.3% 对 88.0%）。0.5:0.5 的集成混合达到 73.4%（对半重采样 0.734 ± 0.015），名义上高于 al1000 标签混合。

规模化：1K AL → 5.9K 混合。 持平结果引出自然的问题——如果 LLM 标签在 1K 规模可替代 al1000 发布标签，它能否在人工无法企及的规模上继续扩展？我们采样了 **al5000**：下一批 5,000 条按边际/熵选取的语料评论（与 al1000 相同的采样区间与类别配额，且与全部 lab2000 文本不相交），用 DeepSeek-V4.1-Flash 标注（4,906 条可解析；标签分布 1,563 正面 / 2,552 中性 / 791 负

面——按设计偏中性），并用同一 SFT 配方训练。AL 行数达 ∼6.5K 时，最优轮数移至 4（8 轮过拟合；e4 对 e8 的选择基于 ood1000，属单一离散的超参披露决策——见第 9 节）。

Table 9: AL 规模扩展在 ood1000 上的结果（标签构成：479 条人工终审 + 双遍 LLM 共识；各集合拆分见第 3.5 节）。所有行均为金标-600 + 所列 AL 数据的 MacBERT SFT。“mix”行为 v3 与 SFT 模型的概率平均；融合权重由分层 5 折交叉验证选定（样本外预测，不会使用该行自身标签调权）。范围为随机种子间波动（三分类五种子、二分类四种子）。二分类评测剔除中性样本；“—”= 未报告。

AL 训练数据	三分类 acc / F1	二分类 acc / F1
仅金标-600	0.626 / 0.611	0.832 / 0.831
金标-600 + al1000（发布）	0.714 / 0.710	0.880 / 0.875
金标-600 + al1000（DS 标签）	0.713 / 0.714	0.863 / 0.860
金标-600 + al5000（DS 标签）	0.719 / 0.720	0.893 / 0.890
金标-600 + al6k（全 DS 标签）	0.725 / 0.727	0.893 / 0.890
金标-600 + al6k（混合）	**0.729 / 0.731**	**0.911 / 0.908**
金标-600 + al11k（1K AL+9.9K DS）	0.734 / 0.737	**0.914 / 0.912**
金标-600 + al11k（1K AL+4.9K DS+5K Qwen3-4B）	0.703 / 0.706	0.902 / 0.898
金标-600 + al11k（全 DS 无 AL 核心）	0.727 / 0.732	0.900 / 0.898
金标-600 + al3k（分歧挖掘 DS）	0.703 / 0.704	0.877 / 0.874
金标-600 + al14k（1K AL+12.9K DS）	0.744 / 0.747	0.914 / 0.911
金标-600 + al17k（1K AL+15.9K DS）	0.730–0.746 / 0.732–0.749	0.915–0.924 / 0.912–0.922
+ v3 混合（al6kh）	0.742 / 0.743	0.909 / 0.907
+ v3 混合（al11kds, 三种子最优）	0.757 / 0.760	—
+ v3 混合（al11kds 三种子平均）	0.749 / 0.752	—
+ v3 混合（al11kds 二分类 e8）	—	0.915 / 0.913
+ v3 混合（al14kds, 三种子）	0.748–0.757	—
+ v3 混合（al14kds 三种子平均）	0.755 / 0.758	—
+ v3 混合（al14kds 二分类）	—	0.909 / 0.907
+ v3 混合（al17kds, 五种子）	0.746–0.763	—
+ v3 混合（al17kds 五种子平均）	**0.771 / 0.774**	—
+ v3 混合（al17kds 二分类 e8 四种子平均）	—	0.923 / 0.920

三个观察。其一，**规模胜过来源**：5,893 条纯 LLM 标签（72.5%）已超过 al1000 发布标签（71.4%）。两个教师的偏差恰好互补：DeepSeek 在歧义行上少判正面（与发布标签正面仅 65% 一致，把 464 条中的 156 条改判为中性），而与 al1000 发布标签在中性上的一致率达 88%——其中的人工终审核心恰好纠正的就是这种极性偏差，这正是混合方案最优的原因。其二，**混合最优**：最困难的 1,000 行保留 al1000 发布标签，再加入 4,906 条 LLM 标签，单模达到 72.9%，混合后达三分类 **74.2% / 0.743**、二分类 **90.9% / 0.907** ——此规模下最强的分布外数字，仍比前沿 LLM 低约 7pp，但延迟约 0.1 秒且完全本地。其三，曲线在 6K 后进入收益递减：我们以两种方式把同一协议推到 ∼11K AL 行——再加一批 5,000 条 DeepSeek 标签（al11k-DS），或换成 5,000 条本地 Qwen3-4B 教师标签（al11k-Qwen；该本地模型在 ood1000 零样本仅 70.6%，对比 DeepSeek 的 82.0%）。全 API 教师方案小幅领先（单模 73.4%、二分类 91.5%，且为 11K 规模模型中金标-600 交叉拟合最优的 81.0%），但三分类混合与 6K 相比统计上持平（三种子均值 74.9% 对 74.2%，McNemar $p = 0.56$）——1K→6K 的增益在 6K→11K 不再重现，标志着歧义区域收益递减的起点；不过相对 1K AL 混合的提升仍显著（McNemar $p = 0.041$，109 比 80 个不一致对），且混合模型的分布外校准同步改善（ECE 0.037 对 v3 的 0.159）。本地教师方案明显更差（单模 70.3%、混合 72.4%、二分类单模 90.2%、交叉拟合 79.5%；与 DS 教师混合的逐对 McNemar 达 $p = 0.041$ ——教师质量差距是真实可测的，而非噪声）：同等规模下伪标签质量而非数量才是约束——4B 开源教师在此无法替代前沿 API。两教师的分歧并非随机而是有结构的：在同一批 5,000 条不确定性采样行上标签一致率仅 62.3%，Qwen 过判正面（把 DS 的 725 条中性行改判正面）、漏

判负面（396 条 DS 负面行被改判中性）——这种分布级偏差被学生原样继承。第三轮实验检验边际上在哪里采样 AL 行是否重要：我们从学生分歧池（两个独立训练的学生变体在 argmax 标签上不一致的行）中挖掘 3,000 条新行，用 DeepSeek 标注（al3kds），并入构成 al14kds（1K AL + 12.9K DS）。仅 3K 子集的标签效率惊人——单模 70.3%、混合 71.5%，大致追平 1K *al1000* 标签混合（72.0%），标签数为其 3 倍但成本为 API token 而非人工终审——而完整 14K 混合达到**三分类 75.5%**（三种子 74.8–75.7%，三种子平均 75.5%）与**二分类 90.9%**，金标-600 交叉拟合 81.5%。相对最优 11K 种子的差异在 n=1000 下处于噪声范围（McNemar $p = 0.91$）；14K 混合相对 1K AL 混合仍显著更优（$p \approx 0.01$，107 比 72 个不一致对）。第四轮相同方案（al17kds，再加 3,000 条分歧挖掘 DeepSeek 行）达到**三分类 77.1%** 五种子平均（单种子 74.6–76.3%）与**二分类 92.3%**，金标-600 交叉拟合 81.0%——目前最优观测数字，但相对 14K 的 +1.6pp 仍在噪声内（McNemar $p = 0.064$），证实三分类已在约 75–77% 带内饱和——诚实的解读是分歧定向采样确有帮助，但三分类曲线正逼近天花板。最后一组消融在同等 11K 规模下把 al1000 发布标签也换成 DeepSeek 标签（al11k 全 DS）：三分类混合不变（75.2%，McNemar $p = 0.80$ 对 al1000 核心混合），二分类同样在噪声内（90.3% 对 91.4%，$p = 0.28$）——此规模下发布的人类标签在两个任务上均无可测的边际价值。诚实的规模曲线因此是：至 ∼6K AL 行快速上升，三分类随后饱和，而二分类与域内稳健性仍在改善。全部 15,906 条新增 DeepSeek 标签的 API 成本仅数十万 token——比同等规模人工标注便宜数个数量级。

分层检验。两个切面回应最直接的质疑。来源构成：al17k 的增益并非 LLM 共识标签的产物——在 800 条共识行上混合比 v3 高 +12.7pp（69.6%→82.4%），在 200 条人工终审行上同样高 +9.5pp（46.5%→56.0%）。终审子集本质上更难（人工终审集中于两轮 LLM 分歧样本），增益在该子集依然复现。同一拆分也偏向 LLM 教师：DeepSeek-Flash 在 800 条共识行上达 87.5%（混合为 82.4%），但在终审行上仅 59.5%（195 条可解析；混合在 200 条终审行上为 58.5%）——共识标签部分编码了教师自身的标注约定，这正是终审子集更具信息量的原因。长度：增益集中在短评——相对 v3 的 +121 个净 discordant 胜场中 58 个落在 ≤20 字行——而 >100 字切片对所有系统仍是最弱（ood1000 上混合 72.4% 对 v3 61.2%；fresh500 上 66.7%），与下文路由分析中" 长度即域信号" 的保留意见一致。校准也随规模改善：OOD ECE 从 v3 的 0.159 降至 al17k 的 0.063、al14k 的 0.027。

全新样本稳健性检验。由于 AL 行按语料不确定性采样、混合权重由 ood1000 上的交叉验证选定，我们额外抽样了 **fresh500**——500 条与金标-600 及直至 al17k 的所有 AL 池零文本重叠的均匀随机语料评论，但行级独立性仅部分成立：fresh500 中 70.2% 的评论 ID 出现在至少一个语料派生训练池中，且部署的语料中性检测器在 fresh500 行的 13.2% 上训练过（ood1000 行的 13.0%；第 6.2 节）。因此 fresh500 是在部分暴露分布上、以教师生成标签进行的复现检验，而非干净的留出集——由同一 DeepSeek 教师标注。混合权重固定为 ood1000 交叉拟合值（三分类取众数折权重 w_{SFT}=0.6；二分类取折中位数 0.5——e8 二分类折权重呈双峰，0.45–0.95）后，旗舰 al17kds 混合三分类得 **77.0%** 对 v3 的 58.8%（McNemar $p = 9.1 \times 10^{-15}$），二分类 **93.7%** 对 86.3%（$p = 1.9 \times 10^{-4}$）——AL 增益在此部分暴露样本上复现，并非基准特异性调参的产物。（较早的 al14k 检查点在同一协议下为 74.6% / 92.6%；独立的 al17k SFT 学生在 fresh500 上五种子平均三分类达 78.0%——冻结的 ood1000 调权混合并不能完美迁移到新分布。）（注意：fresh500 标签为教师生成而非人工金标，因此这些数字度量的是对教师标签分布的泛化；二分类歧义较小，受此对齐影响较小。）

这一结果验证的正是 lab2000 自身所用的实用协议：*LLM* 大规模标注 + 人工终审验证核心。第 10 节未来工作 (ii) 由此部分实现。

部署权衡（实测而非假设）。 自然的问题是：分布外加固后的混合模型是否应替换 v3 进入演示系统。我们对此做了诚实检验：SFT 分量在金标-600 上做了交叉拟合（5 折，每折留出 120 条金标、其余金标加全部 al1000 训练），再与 v3 的 OOF 概率混合。SFT 学生单独在金标-600 上仅达 **80.0% / 0.730**（规模化的 al6k 混合变体为 80.2% / 0.737，al11k-DS 变体为 81.0% / 0.751，al14k-DS 变体为 81.5%，al17k-DS 变体为 81.0%；v3 为 89.5% / 0.859），且 SFT 权重较高的混合

落在 80–82%（较轻权重可达 85.8–88.5%；没有任何权重超过 v3 的 89.5%）——在简短歧义 AL 样本上训练会把决策边界推离更长、单影片的金标分布。因此分布外加固与域内准确率在此处相互拉扯；我们保留 v3 作为部署模型，将混合模型作为分布外专家候选报告。长度感知路由器（短评 → 混合、长评 → v3）描绘的是帕累托前沿而非免费午餐：阈值取 20 字时为金标 87.3% / 分布外 71.0%，介于 v3（89.5% / 65.0%）与纯混合（约 82% / 77.1%）之间。长度只是不完美的领域信号（金标 32% 评论不足 50 字，ood1000 中 26% 达 50 字以上），因此学习式领域路由留待未来工作。表 10 给出固定融合权重（w_{SFT}=0.6，交叉拟合众数值）下的完整前沿：每个阈值都以金标准确率换取分布外准确率，没有占优点。

Table 10: 长度路由前沿：$\leq T$ 字的评论路由至 AL 混合模型，更长者路由至 v3（固定 w_{SFT}=0.6 融合）。金标-600 与 ood1000 三分类准确率；纯混合端点的交叉拟合样本外估计为 0.771（表 9）。

阈值 T	金标-600	ood1000
0（纯 v3）	0.895	0.650
20	0.873	0.710
50	0.865	0.742
100	0.845	0.760
∞（纯混合）	0.822	0.774

8.6 lab2000 不宣称什么

al1000 是训练集；其头条数字（如评分规则对比）刻画的是难度而非泛化。479 条人工终审行为非随机、分歧富集子集；其上的准确率对所有系统都偏低，仅用于 LLM 对比。LLM 辅助预标注经一名作者人工终审，另有 200 行第二人类标注抽样；发布数据按行标注了来源（`final_source`），下游用户如需要可仅保留 479 行人工核验核心子集。

9 局限性与效度威胁

- **领域狭窄（已缓解，未消除）。**金标集是来自单一影片页面的 600 条评论；lab2000 研究量化了由此产生的分布外差距（三分类 65.0%），并表明 1,000 条经主动学习选取的样本（混合标签来源：279 行人工终审 + 721 行 LLM 共识）可恢复大部分差距（72.0%）。但 ood1000 并非留出测试——它是开发集（下一条）——因此恢复后的 72.0% 是开发集估计。
- **ood1000 是开发集而非测试集。**第二阶段的全部选择决策——AL 规模（1K→17K）、教师选择（DeepSeek / 本地 Qwen / 混合）、epoch 数（e4/e8）、种子子集、约 26 种混合配置对应约 73 次 SFT 运行，以及 5 折交叉拟合融合权重——均在 ood1000 上做出。报告的 ood1000 数字因此是带约 +0.3–1.0pp best-of-N 乐观偏差的开发集估计，且在同一集合上计算的 McNemar p 值偏于反保守。唯一计划中的零污染终测是一套新的 400 条盲标人工标注集（进行中）。
- **训练/评估集的行级重叠。** ood1000 的 68.7%、fresh500 的 70.2% 与 lab500 的 74.8% 的评论 ID 出现在至少一个语料派生训练池中；部署的语料中性检测器在 ood1000 行的 13.0% 与 fresh500 行的 13.2% 上训练过。AL/SFT 训练池与测试集之间的评论 ID 重叠为零，金标-600 除少量退化短文本外是干净的。lab500 还不能称为“从未被训练”：早期交叉验证脚本曾把 lab500 行用作自身训练折。
- **lab2000 标签来源。**预标注由 LLM 生成；2,000 行中 479 行经人工终审——收集时界面中可见学生模型预测（存在锚定风险，第 3.5 节）——另有 200 行第二人类标注 IAA 抽样（$\kappa = 0.57$，为人—参照标签的混合口径而非纯人—人 IAA）。共识标签可靠但非绝对正确；数据按行发布了来源标记（`final_source`）。

- **伪标签天花板。**伪标签继承教师偏差；飞轮在一轮后饱和（第二轮平均置信度 0.986 = 记忆化）。lab2000 结果表明教师的狭窄领域先验是分布外伪标签的约束瓶颈。
- **统计功效。**在 $n = 600$ 下，低于约 1pp 的差异无法分辨；lab2000 分布外研究（$n = 1{,}000$）为第二阶段头条结论恢复了统计功效，而金标集上的微小差异仍不可分辨。
- **工程约束。** ROCm/Windows GPU 栈在 13 亿参数特征提取期间需要驱动级重启；推理延迟数字为单卡测量值。

9.1 伦理与数据可用性

本文使用的豆瓣语料来自其服务条款未授权大规模抓取或模型训练的平台；我们仅将其用于非商业研究，且不主张已获许可 (Bender and Friedman, 2018)。仓库卫生通过重写 git 历史（2026-11-09）得以保证：所有发布记录中的评论者标识（昵称、IP 地址、时间戳、评论/用户/影片 ID、投票数）均已剔除，约 1.6 万行主动学习池的原始文本不再分发。约 4,600 条基准与评估评论文本（金标-600、lab2000、fresh500、lab500 及合成行）在去除标识符后保持公开。未取得评论者同意——这些文本均为公开短评——并已将暴露面降至最低；数据集文档遵循 datasheet 惯例 (Gebru et al., 2021)。两项外部处理披露：约 18,500 条去重评论文本被发送至 DeepSeek API 用于伪标注；全部 600 条金标文本在阿里云 PAI 上处理，用于第 7 节的平台对比。

10 结论与未来工作

在真实的低资源中文情感任务上，语料规模伪标注是杠杆最高的成分：它将中性召回率从 54% 提升至 71%，并使单一紧凑学生几乎追平多模型集成。基于语料训练中性检测器的专家分解带来了进一步的已验证增益。仅靠星级评分不足以构成监督——这是实测结论而非假设。

lab2000 研究随后对这一结果进行了诚实的压力测试。金标训练的系统在野外跨影片短评上跌至 65.0% 三分类；1,000 条经主动学习选取的边界样本（混合标签来源：279 条人工终审 + 721 条 LLM 共识）将其恢复至 72.0%（对应 SFT 增益 +8.8pp，McNemar $p = 4.0 \times 10^{-8}$），同一协议经规模扩展并借助前沿 LLM 伪标签可达 **77.1%** 三分类与 **92.3%** 二分类——高于实测的 71.5% 第二标注者一致率参照。三个经验观察由此浮现：主动学习需要金标锚点、领域偏移下硬标签可能优于软蒸馏、以及星级评分恰恰在文本最歧义处成为最强可用信号。与参数量 7630 亿至 1.6 万亿的前沿 LLM 相比，紧凑管线在原始分布外准确率上落后，但在人工终审困难样本上达到持平，且延迟与成本低 1–2 个数量级、数据不出本机。

未来工作：(i) 扩充经终审的 AL 集（第 8.5 节的 DeepSeek 教师试点检验了前沿 LLM 伪标签能否在规模上替代人工终审）；(ii) 使用更强的 LLM 教师对语料重新标注，注入学生缺乏的世界知识——lab2000 表明这正是残余差距的主因；(iii) 测试 MacBERT-large 学生与完整的 271K 不平衡池；(iv) 采用领域对抗或多领域训练，在无需逐领域标注的情况下弥合金标 → 语料的差距。

可复现性

全部脚本、交叉验证预测与实验记录位于项目仓库（`https://github.com/shuakami/douban-sentiment`）。911K 语料为外部数据（研究用途；仅发布约 4.6K 条基准/评估文本且已剔除评论者标识符，主动学习池原始文本不再分发——第 9.1 节）；训练好的检查点发布于 `https://huggingface.co/Shuakami/douban-sentiment-weights`。完整的预处理 → 伪标注 → 训练 → 评估流水线均有脚本端到端覆盖。关键产物：`out/ens_lite_3class_v3.json`（部署的三分类 OOF 预测与概率）、`out/lab500_*`（lab500 先导研究）、`data/reviews_gold_al1000.jsonl` 与 `data/lab2000/`（lab2000 基准：2,000 条终审标签及逐行来源、双遍预标注、DeepSeek/Qwen 教师预测与标签、fresh500 及全部第二阶段实验输出；见 `data/lab2000/README.md`）、`scripts/`（全部训练/评估代码）、`PAPER.md`（精简版报告）。硬件：AMD RX 9070 GRE，ROCm，PyTorch bf16。

A 训练细节与可复现性

A.1 超参数

Table 11: 部署流水线的关键超参数。

组件	设置	取值
蒸馏学生	骨干	`hfl/chinese-macbert-base`
	蒸馏 α/τ	0.5 / 2
	epoch 数 / 最大长度	8 / 256
	折数（OOF）	5
判别器头	骨干	MegatronBERT-1.3B（冻结）
	特征	4096 维（CLS + 均值池化）
	头部	2 层 MLP
中性检测器	骨干	MacBERT-base
	训练行数	115,000（每类上限 6 万，2 epoch）
伪标签池	置信度	$\max p \geq 0.7$
	行数	271,905（56.5K/68.6K/146.8K）
校准	方法	温度缩放
	T	0.37（金标 NLL 拟合）
集成权重	dep	学生 1 : 判别器 2
	spec 混合	0.5
	p_n 配比	0.6 判别器头: 0.4 语料检测器

A.2 产物清单

- `out/ens_lite_3class_v3.json` ——部署的三分类 OOF 预测与概率（全部 600 行）。
- `out/ens_lite_binary.json` ——部署的二分类 OOF。
- `out/lab500_*` ——lab500 先导研究：样本、双 LLM 标签、预测、交叉验证结果。
- `data/reviews_gold_al1000.jsonl` + `data/lab2000/` ——lab2000 基准：2,000 条终审标签（含逐行 `final_source` 来源标记）、双遍预标注、DeepSeek/Qwen 教师预测与标签、fresh500 及全部第二阶段实验输出（见 `data/lab2000/README.md`）。
- `scripts/` ——端到端流水线，涵盖语料预处理、伪标注、语料头训练、蒸馏与集成评估（完整脚本列表见仓库）。
- `web/` + `web-ui/` ——FastAPI 后端与 React 演示。

A.3 环境

Python 3.12，PyTorch（ROCm），`transformers`，AMD RX 9070 GRE GPU。所有 GPU 任务串行执行（并发任务会使 ROCm/Windows 栈崩溃）。模型权重：每个 MacBERT 学生约 400MB；共享的 MegatronBERT-1.3B 骨干；部署总占用不足 4GB。冷启动约 14 秒，热态推理约 0.1 秒/条。

B 附录：lab500 先导研究

在 lab2000 之前，一项 500 行的先导研究用较弱的仪器回答了同一个分布外问题。从 911K 语料中均匀随机抽取 500 条评论（已去除金标重复），由两个 LLM 标注员（一个通用助手模型与

Qwen3-4B 零样本 (Qwen Team, 2025)）独立标注；部署的 v3 管线为全部样本打分。

Table 12: lab500 先导研究结果（已被 lab2000 取代）。“—” = 本次未报告。

评估者	参照	n	准确率
v3 集成	LLM-A 标签	500	0.604
Qwen3-4B	LLM-A 标签	500	0.662
v3 集成	双遍 LLM 共识	331	0.740
v3 二分类	LLM-A 标签	255	**0.918**
MacBERT 交叉验证	留出标签	—	0.600 OOF

两个 LLM 标注员之间的一致率仅 66.2%，一个在 400 条域内标签上训练的 MacBERT 模型对留出标签的 OOF 复现率也只有 60%——这直接推动了规模更大、经人工终审的 lab2000 基准的构建。（后续审计发现该交叉验证脚本曾把 lab500 行用作自身训练折，因此 lab500 不能称为“从未被训练”；第 9 节。）教师认为容易的样本（置信度 ≥ 0.7）上所有标注对都达到 0.757；难样本约 0.53。

References

J. Devlin, M.-W. Chang, K. Lee, K. Toutanova. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019. https://arxiv.org/abs/1810.04805.

Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, V. Stoyanov. *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. *arXiv preprint arXiv:1907.11692*, 2019. https://arxiv.org/abs/1907.11692.

Y. Cui, W. Che, T. Liu, B. Qin, Z. Yang, S. Wang, G. Hu. *Revisiting Pre-Trained Models for Chinese Natural Language Processing*. In *Findings of EMNLP*, pages 657–668, 2020. https://arxiv.org/abs/2004.13922.

W. Wang, B. Bi, M. Yan, C. Wu, Z. Bao, J. Xia, L. Peng, L. Si. *StructBERT: Incorporating Language Structures into Pre-training for Deep Language Understanding*. In *International Conference on Learning Representations (ICLR)*, 2020. https://arxiv.org/abs/1908.04577.

Y. Sun, S. Wang, Y. Li, S. Feng, X. Chen, H. Zhang, X. Tian, D. Zhu, H. Tian, H. Wu. *ERNIE: Enhanced Representation through Knowledge Integration*. *arXiv preprint arXiv:1904.09223*, 2019. https://arxiv.org/abs/1904.09223.

IDEA-CCNL. *Erlangshen-MegatronBert-1.3B-Sentiment*: model card and weights. Hugging Face model hub, 2023. https://huggingface.co/IDEA-CCNL/Erlangshen-MegatronBert-1.3B-Sentiment.

Y. Kim. *Convolutional Neural Networks for Sentence Classification*. In *Proceedings of EMNLP*, pages 1746–1751, 2014. https://aclanthology.org/D14-1181/.

R. Socher, A. Perelygin, J. Wu, J. Chuang, C. D. Manning, A. Y. Ng, C. Potts. *Recursive Deep Models for Semantic Compositionality Over a Sentiment Treebank*. In *Proceedings of EMNLP*, pages 1631–1642, 2013. https://aclanthology.org/D13-1170/.

B. Pang, L. Lee. *Opinion Mining and Sentiment Analysis*. *Foundations and Trends in Information Retrieval*, 2(1–2):1–135, 2008. https://doi.org/10.1561/1500000011.

S. Tan, J. Zhang. *An Empirical Study of Sentiment Analysis for Chinese Documents*. *Expert Systems with Applications*, 34(4):2622–2629, 2008. https://doi.org/10.1016/j.eswa.2007.05.028.

D. Yarowsky. *Unsupervised Word Sense Disambiguation Rivaling Supervised Methods*. In *Proceedings of ACL*, pages 189–196, 1995. https://aclanthology.org/P95-1026/.

D.-H. Lee. *Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks*. ICML 2013 Workshop on Challenges in Representation Learning, 2013.

E. Arazo, D. Ortego, P. Albert, N. E. O'Connor, K. McGuinness. *Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning*. In *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*, IEEE, 2020. https://doi.org/10.1109/IJCNN48605.2020.9207304.

A. Ratner, S. H. Bach, H. R. Ehrenberg, J. Fries, S. Wu, C. Ré. *Snorkel: Rapid Training Data Creation with Weak Supervision*. *Proceedings of the VLDB Endowment*, 11(3):269–282, 2017. https://arxiv.org/abs/1711.10160.

Q. Xie, M.-T. Luong, E. Hovy, Q. V. Le. *Self-Training with Noisy Student Improves ImageNet Classification*. In *Proceedings of CVPR*, 2020. https://arxiv.org/abs/1911.04252.

Q. Xie, Z. Dai, E. Hovy, M.-T. Luong, Q. V. Le. *Unsupervised Data Augmentation for Consistency Training*. In *Advances in NeurIPS*, 2020. https://arxiv.org/abs/1904.12848.

K. Sohn, D. Berthelot, N. Carlini, Z. Zhang, H. Zhang, C. A. Raffel, E. D. Cubuk, A. Kurakin, C.-L. Li. *FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence*. In *Advances in NeurIPS*, 2020. https://arxiv.org/abs/2001.07685.

G. Hinton, O. Vinyals, J. Dean. *Distilling the Knowledge in a Neural Network*. *arXiv preprint arXiv:1503.02531*, 2015. https://arxiv.org/abs/1503.02531.

J. Gou, B. Yu, S. J. Maybank, D. Tao. *Knowledge Distillation: A Survey*. *International Journal of Computer Vision*, 129(6):1789–1819, 2021. https://arxiv.org/abs/2006.05525.

A. Joulin, E. Grave, P. Bojanowski, T. Mikolov. *Bag of Tricks for Efficient Text Classification*. In *Proceedings of EACL*, pages 427–431, 2017. https://aclanthology.org/E17-2068/.

N. Reimers, I. Gurevych. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019. https://arxiv.org/abs/1908.10084.

C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. *On Calibration of Modern Neural Networks*. In *Proceedings of ICML*, pages 1321–1330, 2017. https://proceedings.mlr.press/v70/guo17a.html.

Qwen Team. *Qwen3: Technical Report and Model Release*. GitHub repository and model documentation, 2025. https://github.com/QwenLM/Qwen3.

B. Settles. *Active Learning Literature Survey*. University of Wisconsin–Madison, Computer Sciences Technical Report 1648, 2009. https://minds.wisconsin.edu/handle/1793/60660.

F. Gilardi, M. Alizadeh, M. Kubli. *ChatGPT Outperforms Crowd-Workers for Text-Annotation Tasks*. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120, 2023. https://doi.org/10.1073/pnas.2305016120.

P. Törnberg. *ChatGPT-4 Outperforms Experts and Crowd Workers in Annotating Political Twitter Messages with Zero-Shot Learning*. *arXiv preprint arXiv:2304.06588*, 2023. https://arxiv.org/abs/2304.06588.

T. G. Dietterich. *Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms*. *Neural Computation*, 10(7):1895–1923, 1998. https://doi.org/10.1162/089976698300017197.

J. Demšar. *Statistical Comparisons of Classifiers over Multiple Data Sets*. *Journal of Machine Learning Research*, 7:1–30, 2006. https://jmlr.org/papers/v7/demsar06a.html.

B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, London, 1993.

Q. McNemar. *Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages*. *Psychometrika*, 12(2):153–157, 1947. https://doi.org/10.1007/BF02295996.

csuldw. Moviedata-10M: a large-scale Douban movie dataset (140,502 films, 4,428,475 comments, collected 2019). AntSpider project, Central South University, 2019. https://github.com/csuldw/AntSpider. Research use only; the raw corpus is not redistributed here.

B. Pang, L. Lee. *Seeing Stars: Exploiting Class Relationships for Sentiment Categorization with Respect to Rating Scales*. In *Proceedings of ACL 2005*, pages 115–124, 2005. https://aclanthology.org/P05-1015/.

R. Abaiyan et al. *Fault of Our Stars: Behavioral Drivers of Rating–Sentiment Incongruence*. arXiv:2606.25518, 2026. https://arxiv.org/abs/2606.25518.

樊振, 过弋, 张振豪, 韩美琪. 基于词典和弱标注信息的电影评论情感分析.《计算机应用》38(11):3084–3088, 2018.

K. Martins, P. O. S. Vaz-de-Melo, R. Santos. *Why Do Document-Level Polarity Classifiers Fail?* In *Proceedings of NAACL 2021*, pages 1782–1794, 2021. https://aclanthology.org/2021.naacl-main.143/.

J. Zhang, Y. Yu, Y. Li, Y. Wang, Y. Yang, M. Yang, A. Ratner. *WRENCH: A Comprehensive Benchmark for Weak Supervision*. In *Advances in Neural Information Processing Systems (Datasets and Benchmarks)*, 2021. https://arxiv.org/abs/2109.11377.

S. Zhang, Y. Luo, Z. Lyu, X. Chen. *ShiftKD: Benchmarking Knowledge Distillation under Distribution Shift*. *Neural Networks*, 192:107838, 2025. https://doi.org/10.1016/j.neunet.2025.107838.

A. G. Møller, A. Pera, J. A. Dalsgaard, L. M. Aiello. *The Parrot Dilemma: Human-Labeled vs. LLM-Augmented Data in Classification Tasks*. In *Proceedings of EACL 2024 (Volume 2: Short Papers)*, pp. 179–192, 2024. https://doi.org/10.18653/v1/2024.eacl-short.17.

H. Schroeder, D. Roy, J. Kabbara. *Just Put a Human in the Loop? Investigating LLM-Assisted Annotation for Subjective Tasks*. In *Findings of ACL 2025*, pages 25771–25795, 2025. https://aclanthology.org/2025.findings-acl.1323/.

H. Tian, C. Gao, X. Xiao, H. Liu, B. He, H. Wu, H. Wang, F. Wu. *SKEP: Sentiment Knowledge Enhanced Pre-training for Sentiment Analysis*. In *Proceedings of ACL*, pages 4067–4076, 2020. https://aclanthology.org/2020.acl-main.374/.

R. Dror, G. Baumer, S. Shlomov, R. Reichart. *The Hitchhiker's Guide to Testing Statistical Significance in Natural Language Processing*. In *Proceedings of ACL*, pages 1383–1392, 2018. https://aclanthology.org/P18-1128/.

R. Artstein, M. Poesio. *Inter-Coder Agreement for Computational Linguistics*. *Computational Linguistics*, 34(4):555–596, 2008. https://doi.org/10.1162/coli.07-034-R2.

A. M. Davani, M. Díaz, V. Prabhakaran. *Dealing with Disagreements: Looking Beyond the Majority Vote in Subjective Annotations*. *Transactions of the ACL*, 10:92–110, 2022. https://doi.org/10.1162/tacl_a_00449.

E. M. Bender, B. Friedman. *Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science*. *Transactions of the ACL*, 6:587–604, 2018. https://doi.org/10.1162/tacl_a_00041.

T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, K. Crawford. *Datasheets for Datasets*. *Communications of the ACM*, 64(12):86–92, 2021. https://doi.org/10.1145/3458723.

C. G. Northcutt, L. Jiang, I. L. Chuang. *Confident Learning: Estimating Uncertainty in Dataset Labels*. *Journal of Artificial Intelligence Research*, 70:1373–1411, 2021. https://doi.org/10.1613/jair.1.12125.

O. Sainz, J. Campos, I. García-Ferrero, J. Etxaniz, O. L. de Lacalle, E. Agirre. *NLP Evaluation in Trouble: On the Need to Measure LLM Data Contamination for Each Benchmark*. In *Findings of EMNLP*, pages 10776–10787, 2023. https://aclanthology.org/2023.findings-emnlp.722/.

S. Kapoor, A. Narayanan. *Leakage and the Reproducibility Crisis in Machine-Learning-Based Science*. *Patterns*, 4(9):100804, 2023. https://doi.org/10.1016/j.patter.2023.100804.

S. Balloccu, P. Schmidtová, M. Lango, O. Dušek. *Leak, Cheat, Repeat: Data Contamination and Evaluation Malpractices in Closed-Source LLMs*. In *Proceedings of EACL 2024 (Volume 1: Long Papers)*, pages 67–93, 2024. https://aclanthology.org/2024.eacl-long.5/.

M. Kunilovskaya, G. Bhatia, L. S. Albertelli, Y. Chen, C. Greisinger, L. Kiefer, C. Leiter, S. Roy, T. A. Bizuneh, M. A. Manzoor, S. Pohl, Y. Hou, S. Eger. *Who Annotates in NLP? A Large-scale Assessment of Human Annotation Reporting between 2018 and 2025*. In *Proceedings of EMNLP*, pages 9085–9120, 2026. https://aclanthology.org/2026.emnlp-main.396/.

H. Al-Khalifa. *Twenty-Five Years of Inter-Annotator Agreement in NLP: A Systematic Survey of Trends, Metrics, and Reporting Practices*. In *Proceedings of AACL-IJCNLP 2026 (Volume 1: Long Papers)*, pages 579–602, 2026. https://aclanthology.org/2026.aacl-long.27/.

N. Neveditsin, P. Lingras, V. K. Mago. *From Annotation to Adaptation: Metrics, Synthetic Data, and Aspect Extraction for Aspect-Based Sentiment Analysis with Large Language Models*. In *NAACL 2025 Student Research Workshop*, pages 142–161, 2025. https://aclanthology.org/2025.naacl-srw.14/.

Y. Zenimoto, R. Hasegawa, T. Utsuro, M. Yoshioka, N. Kando. *Coding Open-Ended Responses using Pseudo Response Generation by Large Language Models*. In *NAACL 2024 Student Research Workshop*, pages 242–254, 2024. https://aclanthology.org/2024.naacl-srw.26/.